

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH
KHOA CÔNG NGHỆ THÔNG TIN



BÁO CÁO KHÓA LUẬN TỐT NGHIỆP

Phát triển mô hình hỏi đáp tin cậy bệnh
lý về xương dựa trên mô hình ngôn ngữ
lớn và truy xuất tăng cường sinh nội
dung dựa trên văn bản

Giảng viên hướng dẫn:

Giảng viên hướng dẫn

Sinh viên thực hiện:

Sinh viên thực hiện

Thành phố Hồ Chí Minh, Ngày 30 tháng 7 năm 2026

Mục lục

Chương 1: Tổng quan nghiên cứu	1
1.1 Bối cảnh nghiên cứu	1
1.1.1 Thực trạng tiếp cận thông tin y khoa về bệnh lý về xương	1
1.1.2 Sự tiến hóa của hệ thống hỏi–đáp y tế	2
1.1.3 Thách thức và khoảng trống nghiên cứu	2
1.2 Động lực nghiên cứu	4
1.2.1 Ý nghĩa khoa học	4
1.2.2 Ý nghĩa thực tiễn	4
1.3 Phát biểu bài toán và hai pipeline của hệ thống	5
1.3.1 Đầu vào và đầu ra của bài toán	5
1.3.2 Các tham số cần học và biến trung gian	6
1.3.3 Nguyên lý và phát biểu toán học tổng quát	7
1.3.4 Pipeline huấn luyện	7
1.3.4.1 Bước 1: Thu thập và tiền xử lý dữ liệu	8
1.3.4.2 Bước 2: Lập chỉ mục tri thức và huấn luyện bộ truy xuất	8
1.3.4.3 Bước 3: Tạo dữ liệu huấn luyện RAG	9
1.3.4.4 Bước 4: Tinh chỉnh LLM và lớp quyết định	9
1.3.4.5 Bước 5: Đánh giá và lựa chọn mô hình	10
1.3.5 Pipeline suy diễn	10
1.3.5.1 Bước 1: Hiểu và tiền xử lý truy vấn	11
1.3.5.2 Bước 2: Truy xuất bằng chứng	11
1.3.5.3 Bước 3: Xây dựng câu lệnh	11
1.3.5.4 Bước 4: Sinh câu trả lời nháp	11
1.3.5.5 Bước 5: Kiểm tra chất lượng và ra quyết định	12

1.4	Đóng góp của nghiên cứu	12
	Tài liệu tham khảo	14

Danh sách hình vẽ

1.1	Pipeline huấn luyện của hệ thống hỏi–đáp y khoa dựa trên RAG	7
1.2	Pipeline suy diễn và cơ chế quyết định phản hồi của hệ thống	10

Danh sách bảng

Chương 1. Tổng quan nghiên cứu

1.1 Bối cảnh nghiên cứu

1.1.1 Thực trạng tiếp cận thông tin y khoa về bệnh lý về xương

Trong bối cảnh y học hiện đại, khối lượng tri thức lâm sàng, báo cáo thực nghiệm và phác đồ điều trị các bệnh lý về xương, bao gồm loãng xương, thoái hóa xương khớp, gãy xương và viêm xương, đang gia tăng nhanh chóng [15]. Sự tích lũy tri thức quy mô lớn vừa mở ra cơ hội nâng cao chất lượng chăm sóc sức khỏe, vừa làm cho việc tìm đúng thông tin cập nhật và phù hợp với từng trường hợp trở nên khó khăn hơn [9].

Đối với bác sĩ, nhân viên y tế và sinh viên y khoa, việc tra cứu và tổng hợp dữ liệu từ sách chuyên ngành, hướng dẫn lâm sàng và cơ sở dữ liệu y sinh đòi hỏi nhiều thời gian [12]. Trong môi trường thực hành có áp lực cao, quá trình này có thể làm chậm việc tiếp cận bằng chứng phục vụ quyết định chuyên môn. Đối với người bệnh và cộng đồng, việc tự tìm kiếm triệu chứng hoặc phương pháp điều trị trên Internet lại tiềm ẩn nguy cơ tiếp cận nguồn tin sai lệch, dẫn đến tự chẩn đoán hoặc tự điều trị không an toàn. Hai nhóm nhu cầu trên cùng đặt ra yêu cầu về một công cụ tra cứu nhanh, minh bạch nguồn và có cơ chế kiểm soát rủi ro.

Các mô hình ngôn ngữ lớn (Large Language Model, LLM) đã đạt kết quả đáng chú ý trên nhiều bộ dữ liệu hỏi–đáp y khoa, nhưng kết quả cao trên câu hỏi dạng thi hoặc một miền thử nghiệm hẹp chưa đồng nghĩa với khả năng sử dụng an toàn trong chăm sóc người bệnh. Khi tình huống lâm sàng phức tạp hoặc thông tin đầu vào chưa đầy đủ, mô hình vẫn có thể tạo câu trả lời trôi chảy nhưng sai, thiếu cảnh báo hoặc không phù hợp với quy trình thực tế. Vì vậy, LLM trong nghiên cứu này được xem là công cụ hỗ trợ truy xuất và tổng hợp thông tin, không phải hệ thống tự chủ thay thế bác sĩ.

1.1.2 Sự tiến hóa của hệ thống hỏi–đáp y tế

Các hệ thống hỏi–đáp y tế ban đầu chủ yếu dựa trên tập luật hỗ trợ quyết định lâm sàng [1, 2] và các thuật toán truy xuất từ khóa như BM25 hoặc TF–IDF. Cách tiếp cận này dễ kiểm soát nhưng thiếu linh hoạt trước các cách diễn đạt đa dạng, từ đồng nghĩa và ngữ cảnh phức tạp trong ngôn ngữ tự nhiên.

Sự xuất hiện của kiến trúc Transformer [3] thúc đẩy sự phát triển của LLM với khả năng hiểu và sinh văn bản tự nhiên. Tuy nhiên, tri thức lưu trong tham số mô hình có thể lỗi thời khi hướng dẫn lâm sàng thay đổi; người dùng khó xác định nguồn hỗ trợ cho câu trả lời; và mô hình có thể tạo thông tin nghe hợp lý nhưng không có căn cứ, thường được gọi là hiện tượng ảo giác. Những giới hạn này đặc biệt nguy hiểm đối với câu hỏi về thuốc, chống chỉ định, chẩn đoán hoặc xử trí tình huống nguy cơ cao.

Để bổ sung nguồn tri thức có thể kiểm chứng cho LLM, kiến trúc truy xuất tăng cường sinh nội dung (Retrieval-Augmented Generation, RAG) được đề xuất [5, 4].

Định nghĩa 1.1 (Truy xuất tăng cường sinh nội dung (RAG)). RAG là một kỹ thuật và mẫu thiết kế hệ thống kết hợp LLM với hệ thống truy xuất thông tin bên ngoài như cơ sở tri thức, chỉ mục tìm kiếm hoặc cơ sở dữ liệu [13, 14]. Dựa trên truy vấn của người dùng, hệ thống tìm các nội dung liên quan để cung cấp ngữ cảnh cho mô hình sinh [6], nhờ đó câu trả lời có thể dựa trên dữ liệu miền chuyên biệt và được cập nhật mà không cần tái huấn luyện toàn bộ LLM.

RAG cho phép tách nguồn tri thức nghiệp vụ khỏi tham số của mô hình và đã cho thấy khả năng cải thiện hiệu quả hỏi–đáp y khoa [9, 8]. Tuy nhiên, đây không phải cơ chế bảo đảm câu trả lời luôn đúng: sai sót ở kho tri thức hoặc bộ truy xuất có thể tiếp tục lan truyền sang mô hình sinh. Vì vậy, hiệu quả của hệ thống phải được xem xét trên toàn bộ chuỗi xử lý thay vì chỉ đánh giá riêng LLM.

1.1.3 Thách thức và khoảng trống nghiên cứu

Từ thực trạng trên, các thách thức và khoảng trống của bài toán được tổng hợp thành năm nhóm liên kết với nhau:

- (1) **Chất lượng và tính thời điểm của dữ liệu:** Tài liệu y khoa có nhiều định dạng, có thể chứa bảng hoặc sơ đồ khó trích xuất, sử dụng thuật ngữ không đồng nhất và tồn tại ở nhiều

phiên bản. Sự khác biệt giữa hướng dẫn quốc tế, quy trình địa phương hoặc thời điểm ban hành khiến một đoạn tài liệu lỗi thời vẫn có thể được truy xuất nếu hệ thống không quản lý nguồn, phiên bản, phạm vi áp dụng và trạng thái hiệu lực.

- (2) **Giới hạn của truy xuất:** Truy xuất từ khóa có thể bỏ sót tài liệu khi cách diễn đạt của người dùng khác thuật ngữ chuyên môn, trong khi truy xuất ngữ nghĩa có thể chọn các đoạn tương tự về chủ đề nhưng thiếu chi tiết quyết định như liều lượng hoặc chống chỉ định [9, 8]. Bài toán còn phải xử lý sự khác biệt giữa tiếng Việt, tiếng Anh, từ viết tắt và tên gọi thông dụng của cùng một khái niệm y khoa.
- (3) **Đứt gãy ngữ cảnh và suy luận đa bước:** Việc chia tài liệu thành các đoạn độc lập có thể làm mất liên kết giữa triệu chứng, phác đồ, chỉ định và bệnh nền. Các câu hỏi phức tạp vì thế cần tổng hợp nhiều bằng chứng thay vì dựa trên một đoạn đơn lẻ [10]. Trong hội thoại nhiều lượt, lịch sử tích lũy còn có thể gây lệch ngữ cảnh; hệ thống phải lọc và cô đọng lịch sử trước khi viết lại câu hỏi thành truy vấn độc lập.
- (4) **Độ tin cậy và minh bạch bằng chứng:** RAG không loại bỏ hoàn toàn ảo giác. Tài liệu nhiễu, thiếu hoặc mâu thuẫn có thể dẫn đến suy luận sai, bỏ sót cảnh báo, từ chối quá mức hoặc gán sai nguồn trích dẫn [11, 8]. Do đó, từng luận điểm quan trọng trong câu trả lời cần được đối chiếu với bằng chứng thay vì chỉ dựa vào độ trôi chảy của văn bản.
- (5) **An toàn, đánh giá và bảo vệ dữ liệu:** Các độ đo tương đồng bề mặt như BLEU hoặc ROUGE không phản ánh đầy đủ độ chính xác lâm sàng, tính đầy đủ hay nguy cơ gây hại. Việc đánh giá phải tách riêng chất lượng truy xuất, câu trả lời, trích dẫn và hành vi từ chối hoặc chuyển chuyên gia. Đồng thời, bối cảnh bệnh nhân và lịch sử hội thoại phải được giảm thiểu, ẩn danh và sử dụng dưới sự giám sát của con người.

Khoảng trống trọng tâm vì thế không còn là việc áp dụng một pipeline RAG cơ bản, mà là xây dựng và đánh giá một hệ thống hỏi–đáp chuyên biệt cho các bệnh lý về xương có khả năng phối hợp truy xuất lai và song ngữ, sử dụng ngữ cảnh hội thoại có chọn lọc, kiểm tra mức độ bám sát bằng chứng và lựa chọn giữa ba hành động trả lời, từ chối hoặc chuyển đến chuyên gia. Hệ thống cần được đánh giá đồng thời ở ba tầng truy xuất, sinh câu trả lời và hỏi–đáp đầu cuối để xác định chính xác nguồn phát sinh sai sót.

1.2 Động lực nghiên cứu

Việc phát triển một giải pháp hỏi–đáp y khoa tin cậy mang ý nghĩa đối với cả nghiên cứu xử lý ngôn ngữ tự nhiên và hoạt động tra cứu thông tin sức khỏe.

1.2.1 Ý nghĩa khoa học

Về phương diện khoa học, đề tài thiết lập một khung thực nghiệm đầu cuối để khảo sát cách RAG vận hành trên ngữ liệu chuyên ngành về các bệnh lý về xương. Khung này cho phép so sánh RAG cơ sở với các cải tiến về truy xuất lai, tinh chỉnh mô hình bằng bằng chứng và kiểm soát phản hồi an toàn. Thay vì chỉ đo câu trả lời cuối cùng, việc đánh giá riêng ba tầng truy xuất, sinh nội dung và hỏi–đáp đầu cuối giúp xác định lỗi thuộc về kho tri thức, bộ truy xuất, mô hình sinh hay lớp bảo đảm chất lượng [8, 9].

Kết quả thực nghiệm có thể cung cấp mốc so sánh cho các nghiên cứu tiếp theo về hỏi–đáp y khoa tiếng Việt, đặc biệt trong việc cân bằng giữa khả năng trả lời, độ bám sát nguồn và hành vi từ chối hợp lý.

1.2.2 Ý nghĩa thực tiễn

Về phương diện ứng dụng, hệ thống hướng đến việc rút ngắn thời gian tra cứu tài liệu chuyên khoa cho nhân viên y tế và sinh viên, đồng thời cung cấp cho người bệnh một kênh tham khảo ban đầu có nguồn bằng chứng rõ ràng [12]. Cơ chế Answer–Abstain–Escalate giúp biểu đạt giới hạn của hệ thống: chỉ trả lời khi đủ căn cứ, từ chối khi chưa chắc chắn và khuyến nghị gặp chuyên gia khi có nguy cơ.

Giá trị thực tiễn của giải pháp còn nằm ở khả năng cập nhật kho tri thức mà không phải huấn luyện lại toàn bộ LLM, cũng như việc đặt bảo vệ dữ liệu cá nhân và giám sát của con người thành điều kiện vận hành. Hệ thống vì thế đóng vai trò hỗ trợ tra cứu và giáo dục sức khỏe, không thay thế quyết định lâm sàng của bác sĩ.

1.3 Phát biểu bài toán và hai pipeline của hệ thống

1.3.1 Đầu vào và đầu ra của bài toán

Nghiên cứu xem xét bài toán hỏi–đáp y khoa tin cậy dựa trên kiến trúc truy xuất tăng cường sinh nội dung (Retrieval-Augmented Generation, RAG) [5]. Hệ thống kết hợp tri thức y khoa đã được kiểm chứng với mô hình ngôn ngữ lớn (Large Language Model, LLM), qua đó ưu tiên bằng chứng truy xuất thay vì chỉ dựa vào tri thức được ghi nhớ trong tham số mô hình.

Trong giai đoạn huấn luyện, đầu vào thứ nhất là tập tài liệu y khoa đã được kiểm chứng

$$D = \{d_1, d_2, \dots, d_{N_D}\},$$

trong đó d_j là tài liệu thứ j và N_D là số tài liệu. Tập D có thể bao gồm giáo trình, hướng dẫn lâm sàng, phác đồ chẩn đoán–điều trị và các cặp hỏi–đáp đã được chuyên gia xác nhận. Đầu vào thứ hai là bộ dữ liệu hỏi–đáp

$$\mathcal{T}_{QA} = \{(q_i, u_i, h_i, y_i^*)\}_{i=1}^{N_Q},$$

trong đó N_Q là số mẫu huấn luyện; q_i là câu hỏi y khoa; u_i là phần bối cảnh bệnh nhân được phép sử dụng; h_i là lịch sử hội thoại; và y_i^* là câu trả lời chuẩn của mẫu thứ i .

Sau tiền xử lý, tập tài liệu D được phân chia thành tập các đoạn văn bản

$$C = \{c_1, c_2, \dots, c_{N_C}\},$$

trong đó c_j là một đoạn văn bản (chunk) và N_C là tổng số đoạn. Các đoạn cùng siêu dữ liệu và biểu diễn tìm kiếm được lưu trong chỉ mục tri thức I . Với mỗi mẫu hỏi–đáp, hệ thống truy xuất tập bằng chứng $C_i^* \subseteq C$ để hình thành mẫu tinh chỉnh $(q_i, u_i, h_i, C_i^*, y_i^*)$.

Trong giai đoạn suy diễn, đầu vào của một lượt hỏi được biểu diễn bởi

$$X = (q, u, h, I),$$

trong đó q là câu hỏi hiện tại, u là bối cảnh bệnh nhân cần thiết và được phép sử dụng, h là lịch sử hội thoại, còn I là chỉ mục tri thức đã được xây dựng từ tập tài liệu D .

Đầu ra chính không chỉ là một câu trả lời mà là cặp

$$O = (\hat{y}, d), \quad d \in \Delta = \{\text{Answer}, \text{Abstain}, \text{Escalate}\},$$

trong đó $\hat{y}$ là phản hồi cuối cùng và d là quyết định thuộc tập hành động Δ . Quyết định *Answer* được chọn khi bằng chứng đủ mạnh và câu trả lời an toàn; *Abstain* biểu thị việc từ chối trả lời khi bằng chứng thiếu, mâu thuẫn hoặc độ tin cậy thấp; còn *Escalate* chuyển người dùng đến bác sĩ hoặc chuyên gia khi tình huống có nguy cơ cao, khẩn cấp hay vượt phạm vi của hệ thống. Khi phù hợp, đầu ra còn kèm các đoạn bằng chứng, nguồn trích dẫn, độ tin cậy và cảnh báo an toàn.

1.3.2 Các tham số cần học và biến trung gian

Các ẩn cần tìm của bài toán được chia thành hai nhóm. Nhóm thứ nhất là bộ tham số được học hoặc hiệu chỉnh trong giai đoạn huấn luyện:

$$\Theta = \{\phi, \theta, \psi\},$$

trong đó ϕ là tham số của bộ truy xuất, quyết định cách biểu diễn và chấm điểm độ liên quan giữa truy vấn với đoạn tài liệu; θ là tham số của LLM dùng để sinh câu trả lời; và ψ là tham số cùng các ngưỡng của lớp bảo đảm chất lượng, dùng để đánh giá bằng chứng, độ an toàn và lựa chọn quyết định cuối cùng.

Nhóm thứ hai gồm các biến phải suy ra cho mỗi lượt hỏi:

- q' : truy vấn độc lập đã được chuẩn hóa từ câu hỏi hiện tại và ngữ cảnh liên quan;
- m và e : lần lượt là ý định y khoa và tập thực thể y khoa được nhận diện trong truy vấn;
- $\mathbf{z}_q \in \mathbb{R}^{d_e}$: vector nhúng d_e chiều của truy vấn;
- $C^* = \{c_{(1)}, \dots, c_{(k)}\} \subseteq C$: tập k đoạn bằng chứng liên quan nhất;
- $\tilde{y}$: câu trả lời nháp do LLM sinh ra;
- $\mathbf{v}$: vector điểm chất lượng gồm độ liên quan, độ bám sát bằng chứng, tính đầy đủ, độ chính xác trích dẫn, độ an toàn và độ tin cậy;
- $d \in \Delta$: quyết định cuối cùng của hệ thống.

1.3.3 Nguyên lý và phát biểu toán học tổng quát

Nguyên lý cốt lõi của bài toán là sinh phản hồi có căn cứ và có chọn lọc. Bộ truy xuất cung cấp bằng chứng từ kho tri thức đã kiểm chứng; LLM tổng hợp câu trả lời trên bằng chứng đó; lớp bảo đảm chất lượng có quyền ngăn câu trả lời hoặc chuyển đến chuyên gia khi điều kiện an toàn không được đáp ứng. Toàn bộ bài toán được biểu diễn bởi ánh xạ

$$F_{\phi, \theta, \psi} : (q, u, h, I) \longrightarrow (C^*, \hat{y}, d).$$


Trong đó, các thành phần đầu vào, đầu ra và tham số đã được định nghĩa ở hai mục trên. Gọi $\mathcal{T}$ là phân phối dữ liệu đánh giá và $\mathcal{U}$ là hàm hữu dụng y khoa phản ánh đồng thời độ chính xác, độ bám sát bằng chứng, độ an toàn và chất lượng quyết định. Bài toán tối ưu tổng quát là

$$(\phi^*, \theta^*, \psi^*) = \arg \max_{\phi, \theta, \psi} \mathbb{E}_{X \sim \mathcal{T}} [\mathcal{U}(F_{\phi, \theta, \psi}(X))].$$

Việc tối ưu phải thỏa mãn các ràng buộc về thời gian phản hồi, bộ nhớ và độ dài của sở ngữ cảnh. Các phép biến đổi cụ thể tạo nên ánh xạ $F_{\phi, \theta, \psi}$ được trình bày trong hai pipeline dưới đây.

1.3.4 Pipeline huấn luyện

Pipeline huấn luyện tạo kho tri thức có thể truy xuất, dữ liệu tinh chỉnh RAG, LLM chuyên biệt và các ngưỡng chất lượng–an toàn. Tổng quan pipeline được trình bày trong Hình 1.1; quy trình gồm năm bước sau.



Hình 1.1: Pipeline huấn luyện của hệ thống hỏi–đáp y khoa dựa trên RAG

1.3.4.1 Bước 1: Thu thập và tiền xử lý dữ liệu

Tập tài liệu D được thu thập từ các nguồn y khoa chính thống như giáo trình, hướng dẫn lâm sàng, phác đồ chẩn đoán–điều trị và các cặp hỏi–đáp đã được kiểm chứng. Tài liệu thô ở dạng PDF, Word, HTML hoặc cơ sở dữ liệu được trích xuất văn bản; loại bỏ đầu trang, chân trang, ký tự lỗi và nội dung trùng lặp; chuẩn hóa thuật ngữ, đơn vị và định dạng; đồng thời loại bỏ hoặc ẩn thông tin nhận dạng bệnh nhân.

Hàm phân đoạn f_{chunk} chuyển tập tài liệu thành các đoạn:

$$C = f_{\text{chunk}}(D; \ell, s),$$

trong đó ℓ là kích thước đoạn và s là bước trượt. Mỗi đoạn c_j được gán siêu dữ liệu μ_j gồm tên tài liệu, chuyên khoa, chủ đề, tổ chức phát hành, ngày ban hành, phiên bản, vị trí trong tài liệu, phạm vi áp dụng, trạng thái hiệu lực và độ tin cậy của nguồn. Đầu ra của bước này là tập các đoạn sạch (c_j, μ_j) đủ thông tin để truy xuất và trích dẫn.

1.3.4.2 Bước 2: Lập chỉ mục tri thức và huấn luyện bộ truy xuất

Mô hình nhúng E_ϕ biến mỗi đoạn c_j thành vector $\mathbf{z}_j = E_\phi(c_j) \in \mathbb{R}^{d_e}$. Vector, nội dung đoạn, siêu dữ liệu và thông tin trích dẫn được lưu trong chỉ mục đặc I_{dense} ; đồng thời, biểu diễn từ khóa được lưu trong chỉ mục thưa I_{sparse} . Chỉ mục tri thức hoàn chỉnh là $I = (I_{\text{dense}}, I_{\text{sparse}})$.

Điểm truy xuất lai giữa truy vấn q và đoạn c được xác định bởi

$$s_\phi(q, c) = \alpha s_{\text{dense}, \phi}(q, c) + (1 - \alpha) s_{\text{sparse}}(q, c),$$

trong đó $s_{\text{dense}, \phi}$ là điểm tương đồng ngữ nghĩa, s_{sparse} là điểm khớp từ khóa và $\alpha \in [0, 1]$ là hệ số phối hợp hai thành phần.

Khi có nhãn đoạn dương và đoạn âm, bộ truy xuất được huấn luyện để đưa câu hỏi gần đoạn liên quan và xa các đoạn không liên quan. Với c_i^+ là đoạn đúng và $\mathcal{B}_i^-$ là tập đoạn âm hoặc âm khó của câu hỏi q_i , hàm mất mát truy xuất được xác định bởi [4]

$$\mathcal{L}_{\text{ret}}(\phi) = - \sum_i \log \frac{\exp(s_\phi(q_i, c_i^+))}{\exp(s_\phi(q_i, c_i^+)) + \sum_{c^- \in \mathcal{B}_i^-} \exp(s_\phi(q_i, c^-))}.$$

Nếu tham số ϕ được cập nhật, toàn bộ vector đoạn phải được tạo lại và chỉ mục I_{dense} phải được cập nhật trước các bước tiếp theo.

1.3.4.3 Bước 3: Tạo dữ liệu huấn luyện RAG

Từ bộ $\mathcal{T}_{\text{QA}}$, câu hỏi được chuẩn hóa hoặc mở rộng bằng các cách diễn đạt tương đương, câu hỏi sinh từ tài liệu, câu hỏi nối tiếp trong hội thoại và trường hợp cố ý thiếu bằng chứng. Với mỗi câu hỏi, hệ thống thực hiện truy xuất lai, lấy Top- k đoạn, lọc theo siêu dữ liệu và có thể xếp hạng lại để thu được C_i^* .

Tập mẫu tinh chỉnh được tạo thành

$$\mathcal{T}_{\text{RAG}} = \{(q_i, u_i, \bar{h}_i, C_i^*, y_i^*, d_i^*)\}_{i=1}^{N_Q},$$

trong đó $\bar{h}_i$ là lịch sử đã cô đọng và $d_i^* \in \Delta$ là nhãn hành động chuẩn. Mỗi mẫu dạy mô hình đọc bằng chứng, trả lời dựa trên nguồn, trích dẫn đúng, biểu đạt độ không chắc chắn, từ chối khi bằng chứng không đủ và chuyển chuyên gia đối với tình huống nguy cơ cao.

1.3.4.4 Bước 4: Tinh chỉnh LLM và lớp quyết định

LLM nền được tinh chỉnh có giám sát (Supervised Fine-Tuning, SFT) trên $\mathcal{T}_{\text{RAG}}$. Hàm mất mát sinh câu trả lời là

$$\mathcal{L}_{\text{gen}}(\theta) = - \sum_i \sum_{t=1}^{T_i} \log P_{\theta}(y_{i,t}^* \mid y_{i,<t}^*, q_i, u_i, \bar{h}_i, C_i^*),$$

trong đó T_i là độ dài câu trả lời chuẩn và $y_{i,<t}^*$ là các token đứng trước vị trí t . Lớp bảo đảm chất lượng được học hoặc hiệu chỉnh bằng hàm mất mát $\mathcal{L}_{\text{safe}}(\psi)$, bao gồm lỗi phân loại quyết định d_i^* và các lỗi liên quan đến độ bám sát bằng chứng, trích dẫn và an toàn.

Hàm mục tiêu tổng hợp được viết dưới dạng

$$\mathcal{L} = \lambda_{\text{ret}} \mathcal{L}_{\text{ret}} + \lambda_{\text{gen}} \mathcal{L}_{\text{gen}} + \lambda_{\text{safe}} \mathcal{L}_{\text{safe}},$$

trong đó các hệ số không âm λ_{ret} , λ_{gen} và λ_{safe} kiểm soát đóng góp tương đối của ba mục tiêu. Các thành phần có thể được tối ưu theo từng giai đoạn, nhưng phải được đánh giá lại trong cùng một

pipeline đầu cuối.

1.3.4.5 Bước 5: Đánh giá và lựa chọn mô hình


Đánh giá được thực hiện ở ba tầng:

- **Tầng truy xuất:** sử dụng Recall@ k , Precision@ k , Mean Reciprocal Rank (MRR), normalized Discounted Cumulative Gain (nDCG) và tỷ lệ tài liệu chuẩn xuất hiện trong Top- k để kiểm tra khả năng tìm đúng bằng chứng [8].
- **Tầng sinh câu trả lời:** đánh giá độ chính xác y khoa, độ liên quan, độ trung thực và bám sát bằng chứng, tính đầy đủ, tỷ lệ ảo giác, độ chính xác của trích dẫn và độ an toàn [7, 11].
- **Tầng hỏi–đáp đầu cuối:** đánh giá toàn bộ chuỗi từ câu hỏi, truy xuất, xây dựng câu lệnh, sinh câu trả lời, kiểm tra chất lượng đến quyết định cuối cùng; trong đó kiểm tra riêng khả năng trả lời đúng, từ chối đúng và chuyển chuyên gia đúng.

Đầu ra của pipeline huấn luyện gồm chỉ mục tri thức I , tập mẫu $\mathcal{T}_{\text{RAG}}$, LLM hỏi–đáp y khoa đã tinh chỉnh, tham số hoặc ngưỡng chất lượng–an toàn ψ , kết quả đánh giá và checkpoint mô hình tốt nhất.

1.3.5 Pipeline suy diễn

Pipeline suy diễn sử dụng các thành phần đã tạo trong huấn luyện để xử lý một lượt hỏi qua năm bước. Luồng xử lý từ đầu vào đến quyết định Answer–Abstain–Escalate được minh họa trong Hình 1.2.



Hình 1.2: Pipeline suy diễn và cơ chế quyết định phản hồi của hệ thống

1.3.5.1 Bước 1: Hiểu và tiền xử lý truy vấn

Hệ thống tiếp nhận câu hỏi q , bối cảnh bệnh nhân u và lịch sử hội thoại h . Bối cảnh bệnh nhân có thể gồm tuổi, giới tính, triệu chứng, tiền sử, thuốc đang dùng, dị ứng hoặc kết quả xét nghiệm, nhưng chỉ phần dữ liệu cần thiết và được phép mới được sử dụng. Đầu vào được kiểm tra về định dạng, phạm vi, dữ liệu nhạy cảm và dấu hiệu cấp cứu.

Lịch sử h được lọc và cô đọng thành $\bar{h}$ thay vì đưa nguyên văn toàn bộ hội thoại vào câu lệnh. Hàm f_{pre} viết lại câu hỏi nối tiếp thành truy vấn độc lập q' , nhận diện ngôn ngữ, chuẩn hóa thuật ngữ Việt–Anh, xác định ý định m và trích xuất các thực thể e như bệnh, thuốc, triệu chứng, liều lượng, thời gian và yếu tố nguy cơ.

1.3.5.2 Bước 2: Truy xuất bằng chứng

Truy vấn q' được mã hóa thành $\mathbf{z}_q$ bằng cùng mô hình E_ϕ đã dùng khi lập chỉ mục. Hệ thống kết hợp truy xuất đặc và truy xuất thưa theo điểm s_ϕ , lấy Top- k đoạn rồi lọc theo chuyên khoa, ngày ban hành, trạng thái hiệu lực và phạm vi áp dụng. Một bộ xếp hạng lại có thể đưa bằng chứng phù hợp nhất lên đầu và loại các đoạn nhiễu hoặc trùng lặp.

Đầu ra là tập C^* , trong đó mỗi đoạn đi kèm nội dung, nguồn tài liệu, ngày hoặc phiên bản, điểm liên quan và siêu dữ liệu cần thiết để trích dẫn. Nếu bằng chứng không đủ hoặc các nguồn mâu thuẫn nghiêm trọng, tín hiệu này được chuyển đến lớp quyết định thay vì bị che giấu ở bước sinh.

1.3.5.3 Bước 3: Xây dựng câu lệnh

Câu lệnh P gồm chỉ dẫn an toàn I_{safe} , truy vấn đã xử lý q' , phần bối cảnh bệnh nhân u có liên quan, lịch sử cô đọng $\bar{h}$, tập bằng chứng C^* và định dạng đầu ra yêu cầu. Chỉ dẫn an toàn buộc mô hình ưu tiên bằng chứng, không tự tạo chẩn đoán chắc chắn hoặc liều thuốc khi thiếu dữ liệu, nêu rõ giới hạn, và đề nghị gặp chuyên gia khi có dấu hiệu nguy hiểm. Mỗi đoạn bằng chứng được đánh dấu nguồn rõ ràng để hỗ trợ kiểm tra trích dẫn.

1.3.5.4 Bước 4: Sinh câu trả lời nháp

LLM hỏi–đáp y khoa với tham số θ^* đọc câu lệnh P và tạo câu trả lời nháp $\tilde{y}$. Câu trả lời có thể gồm nội dung chính, giải thích, bằng chứng hỗ trợ, trích dẫn, cảnh báo và mức độ không chắc

chẩn. Bản nháp chưa được gửi trực tiếp cho người dùng mà phải qua lớp bảo đảm chất lượng.

1.3.5.5 Bước 5: Kiểm tra chất lượng và ra quyết định

Lớp g_{ψ^*} đánh giá bản nháp theo các tiêu chí: trả lời đúng trọng tâm; được bằng chứng hỗ trợ; không thêm luận điểm ngoài nguồn; trích dẫn đúng; không bỏ sót cảnh báo quan trọng; không gây hại; nhất quán với bối cảnh bệnh nhân; và đủ tin cậy để phản hồi. Kết quả tạo quyết định cuối cùng:

- **Answer:** bằng chứng đủ mạnh, câu trả lời bám sát tài liệu, trích dẫn hợp lệ và không phát hiện rủi ro nghiêm trọng;
- **Abstain:** không tìm được bằng chứng phù hợp, nguồn mâu thuẫn, câu hỏi thiếu thông tin, độ tin cậy thấp hoặc nằm ngoài phạm vi hệ thống;
- **Escalate:** có dấu hiệu cấp cứu, cần khám trực tiếp, liên quan đến quyết định điều trị nguy cơ cao, phản ứng thuốc nghiêm trọng hoặc cần bác sĩ đánh giá hồ sơ đầy đủ.

Như vậy, hai pipeline liên kết với nhau qua chỉ mục tri thức I , mô hình truy xuất ϕ^* , LLM θ^* và lớp quyết định ψ^* . Sự liên kết này bảo đảm các ký hiệu và thành phần được sử dụng thống nhất từ xây dựng dữ liệu, huấn luyện đến vận hành thực tế.

1.4 Đóng góp của nghiên cứu

Trên cơ sở kế thừa khung RAG chuẩn, nghiên cứu hướng đến năm đóng góp sau:

- (1) **Khung hệ thống RAG đầu cuối cho hỏi–đáp y khoa:** Xây dựng hai pipeline huấn luyện và suy diễn thống nhất, liên kết kho tri thức, bộ truy xuất, LLM và lớp bảo đảm chất lượng cho miền bệnh lý về xương; qua đó tạo một baseline có thể tái sử dụng trong các thực nghiệm tiếp theo.
- (2) **Ngữ liệu và bộ câu hỏi đánh giá chuyên ngành:** Thu thập, làm sạch và chuẩn hóa tài liệu y khoa từ các nguồn chính thống, đồng thời xây dựng tập câu hỏi phục vụ huấn luyện và đánh giá hệ thống.
- (3) **Truy xuất lai và song ngữ Việt–Anh:** Phối hợp truy xuất đặc theo ngữ nghĩa với truy

xuất thừa theo từ khóa, kết hợp chuẩn hóa thuật ngữ song ngữ để xử lý sự khác biệt giữa cách diễn đạt thông dụng và ngôn ngữ chuyên môn.

- (4) **Sinh câu trả lời có bằng chứng và cơ chế Answer–Abstain–Escalate:** Tinh chỉnh mô hình bằng các mẫu chứa câu hỏi, ngữ cảnh, bằng chứng và đáp án chuẩn; sau đó kiểm tra chất lượng để quyết định trả lời, từ chối hoặc chuyển đến chuyên gia.
- (5) **Đánh giá thực nghiệm theo nhiều tầng:** Đo lường riêng chất lượng truy xuất, chất lượng sinh và hiệu quả đầu cuối nhằm đánh giá khả năng giảm ảo giác, tăng độ trung thực và xác định thành phần gây lỗi trong hệ thống.

Tài liệu tham khảo

- [1] L. L. E., et al. (2018). **A rule-based clinical decision model to support interpretation of multiple data in health examinations.** *International Journal of Medical Informatics*, 112, 128–135. <https://doi.org/10.1016/j.ijmedinf.2018.01.018>.
- [2] K. M., et al. (2021). **A Hybrid AI and Rule-Based Decision Support System for Disease Diagnosis and Management Using Labs.** *IEEE Access*, 9, 45120–45132. <https://doi.org/10.1109/ACCESS.2021.3066311>.
- [3] Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). **Attention is all you need.** In *Advances in Neural Information Processing Systems* (Vol. 30, pp. 5998–6008). <https://arxiv.org/abs/1706.03762>.
- [4] Karpukhin, V., Oğuz, B., Min, S., Lewis, P., Wu, L., Edunov, S., Chen, D., & Yih, W. T. (2020). **Dense passage retrieval for open-domain question answering.** *arXiv preprint arXiv:2004.04906*. <https://arxiv.org/abs/2004.04906>.
- [5] Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W. T., Rocktäschel, T., Riedel, S., & Kiela, D. (2020). **Retrieval-augmented generation for knowledge-intensive NLP tasks.** In *Advances in Neural Information Processing Systems* (Vol. 33, pp. 9459–9474). <https://arxiv.org/abs/2005.11401>.
- [6] Gao, Y., Xiong, Y., Gao, X., Jia, K., Pan, J., Bi, Y., Dai, Y., Sun, J., & Wang, H. (2023). **Retrieval-augmented generation for large language models: A survey.** *arXiv preprint arXiv:2312.10997*. <https://arxiv.org/abs/2312.10997>.
- [7] Es, S., James, J., Espinosa-Anke, L., & Schockaert, S. (2023). **RAGAS: Automated Evaluation of Retrieval Augmented Generation.** *arXiv preprint arXiv:2309.15217*. <https://arxiv.org/abs/2309.15217>.

- [8] Xiong, G., Jin, Q., Lu, Z., & Zhang, A. (2024). **Benchmarking Retrieval-Augmented Generation for Medicine**. In *Findings of the Association for Computational Linguistics (ACL)*. *arXiv preprint arXiv:2411.09213*. <https://arxiv.org/abs/2411.09213>.
- [9] Xiong, G., et al. (2024). **MedRAG: Towards Reliable Medical Question Answering with Retrieval-Augmented Generation**. *arXiv preprint arXiv:2404.14746*. <https://arxiv.org/abs/2404.14746>.
- [10] Kim, J., et al. (2024). **Improving Retrieval-Augmented Generation in Medicine with Iterative Follow-up Questions**. *arXiv preprint arXiv:2405.03124*. <https://arxiv.org/abs/2405.03124>.
- [11] Zhang, H., et al. (2024). **MedTrust-RAG: Evidence Verification and Trust Alignment for Biomedical Question Answering**. *arXiv preprint arXiv:2406.08210*. <https://arxiv.org/abs/2406.08210>.
- [12] Mueller, M., et al. (2024). **Development and Evaluation of a Retrieval-augmented Generation Chatbot for Orthopedic and Trauma Surgery Patient Education: A Mixed-methods Study**. *JMIR AI*, 3, e54321. <https://doi.org/10.2196/54321>.
- [13] National Institute of Standards and Technology. (2025). **Adversarial Machine Learning: A Taxonomy and Terminology of Attacks and Mitigations**. *NIST AI 100-2e2025*. <https://doi.org/10.6028/NIST.AI.100-2e2025>.
- [14] Cheng, M., Luo, Y., Ouyang, J., Liu, Q., Liu, H., Li, L., Yu, S., Zhang, B., Cao, J., Ma, J., Wang, D., & Chen, E. (2025). **A Survey on Knowledge-Oriented Retrieval-Augmented Generation**. *arXiv preprint arXiv:2503.10677*. <https://arxiv.org/abs/2503.10677>.
- [15] World Health Organization. (2022). **Musculoskeletal Health**. *WHO Fact Sheets*. Truy cập ngày 29/07/2026. <https://www.who.int/news-room/fact-sheets/detail/musculoskeletal-health>.
- [16] Collaco, N., et al. (2026). **Integrating Fine-Tuning and Retrieval-Augmented Generation for Healthcare AI Systems: A Scoping Review**. *Journal of Healthcare Informatics Research*. <https://pubmed.ncbi.nlm.nih.gov/>.