

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH
KHOA CÔNG NGHỆ THÔNG TIN



BÁO CÁO KHÓA LUẬN TỐT NGHIỆP

Phát triển mô hình hỏi đáp tin cậy bệnh
lý về xương dựa trên mô hình ngôn ngữ
lớn và truy xuất tăng cường sinh nội
dung dựa trên văn bản

Giảng viên hướng dẫn:

Giảng viên hướng dẫn

Sinh viên thực hiện:

Sinh viên thực hiện

Thành phố Hồ Chí Minh, Ngày 30 tháng 7 năm 2026

Lời cảm ơn

Nhóm xin trân trọng cảm ơn **PGS. TS. Lý Quốc Ngọc** đã trực tiếp hướng dẫn, giảng dạy các nội dung lý thuyết chính và định hướng khoa học cho đề tài. Nhóm cũng xin cảm ơn **ThS. Nguyễn Mạnh Hùng** và **ThS. Phạm Thanh Tùng** đã hỗ trợ trong quá trình thực hành và cung cấp các kiến thức thực nghiệm quan trọng, góp phần giúp nhóm hoàn thành báo cáo này.

Mục lục

Lời cảm ơn	i
Chương 1: Tổng quan nghiên cứu	1
1.1 Bối cảnh nghiên cứu	1
1.1.1 Thực trạng tiếp cận thông tin y khoa về bệnh lý về xương	1
1.1.2 Sự tiến hóa của các hệ thống hỏi đáp y tế và điểm nghẽn công nghệ	2
1.2 Động lực nghiên cứu	4
1.2.1 Ý nghĩa khoa học	4
1.2.2 Ý nghĩa thực tiễn	4
1.3 Phát biểu bài toán và hai pipeline của hệ thống	5
1.3.1 Đầu vào và đầu ra của bài toán	5
1.3.2 Các tham số cần học và biến trung gian	6
1.3.3 Nguyên lý và phát biểu toán học tổng quát	7
1.3.4 Pipeline huấn luyện	9
1.3.4.1 Bước 1: Thu thập và tiền xử lý dữ liệu	9
1.3.4.2 Bước 2: Lập chỉ mục tri thức và huấn luyện bộ truy xuất	10
1.3.4.3 Bước 3: Tạo dữ liệu huấn luyện RAG	10
1.3.4.4 Bước 4: Tinh chỉnh LLM và lớp quyết định	11
1.3.4.5 Bước 5: Đánh giá và lựa chọn mô hình	11
1.3.5 Pipeline suy diễn	12
1.3.5.1 Bước 1: Hiểu và tiền xử lý truy vấn	12
1.3.5.2 Bước 2: Truy xuất bằng chứng	12
1.3.5.3 Bước 3: Xây dựng câu lệnh	13
1.3.5.4 Bước 4: Sinh câu trả lời nháp	13
1.3.5.5 Bước 5: Kiểm tra chất lượng và ra quyết định	13

1.4	Các thách thức của bài toán	14
1.4.1	Tính không đồng nhất, tính thời điểm và chất lượng của dữ liệu	14
1.4.2	Giới hạn của bộ truy xuất trước rào cản thuật ngữ và nhiều ngữ nghĩa	14
1.4.3	Đứt gãy ngữ cảnh và năng lực suy luận y khoa đa bước	15
1.4.4	Xung đột tri thức và các dạng ảo giác y khoa	15
1.4.5	Sự khẩn khe trong tiêu chuẩn an toàn và đánh giá lâm sàng	16
1.4.6	Bảo vệ dữ liệu cá nhân và duy trì giám sát của con người	16
1.5	Đóng góp của nghiên cứu	16
	Tài liệu tham khảo	18

Danh sách hình vẽ

1.1	Pipeline huấn luyện của hệ thống hỏi–đáp y khoa dựa trên RAG	9
1.2	Pipeline suy diễn và cơ chế quyết định phản hồi của hệ thống	12

Danh sách bảng

Chương 1. Tổng quan nghiên cứu

1.1 Bối cảnh nghiên cứu

1.1.1 Thực trạng tiếp cận thông tin y khoa về bệnh lý về xương

Trong bối cảnh y học hiện đại, khối lượng tri thức lâm sàng, các báo cáo thực nghiệm và phác đồ điều trị các bệnh lý về xương (bao gồm các bệnh lý phổ biến như loãng xương, thoái hóa xương khớp, gãy xương và viêm xương) đang gia tăng với tốc độ nhanh chóng [15]. Sự tích lũy tri thức y học quy mô lớn vừa mở ra cơ hội nâng cao chất lượng chăm sóc sức khỏe, vừa tạo ra thách thức lớn trong việc tiếp cận và khai thác thông tin chính xác [9]. Thách thức này thể hiện rõ nét qua hai góc độ đối tượng sử dụng chính trong xã hội.

Đối với đội ngũ nhân viên y tế và sinh viên y khoa, việc tìm kiếm cũng như tổng hợp dữ liệu lâm sàng từ các bộ tài liệu y học chuyên ngành, sách giáo khoa hoặc cơ sở dữ liệu y sinh quy mô lớn đòi hỏi lượng thời gian đáng kể [12]. Trong môi trường thực hành áp lực cao, thời gian tra cứu kéo dài có thể làm chậm quá trình đưa ra quyết định chẩn đoán và chỉ định phác đồ điều trị [9]. Vì vậy, việc ứng dụng các công cụ tự động hóa nhằm hỗ trợ tra cứu tri thức chuẩn xác với tốc độ phản hồi tức thì là yêu cầu vô cùng cấp thiết.

Đối với người bệnh và cộng đồng, xu hướng tự tra cứu triệu chứng và phương pháp điều trị các bệnh lý về xương trên mạng Internet ngày càng trở nên phổ biến. Tuy nhiên, nguồn tin trên không gian mạng thường rơi vào tình trạng nhiễu loạn và thiếu sự kiểm chứng từ chuyên gia. Việc tiếp cận các dữ liệu sai lệch dễ dẫn đến hành vi tự chẩn đoán sai, tự ý sử dụng thuốc không theo chỉ định, gây ra những biến chứng nguy hiểm. Thực trạng này đặt ra đòi hỏi phải xây dựng các giải pháp công nghệ có khả năng tư vấn y học chính xác, minh bạch, đảm bảo độ an toàn lâm sàng, khả năng đọc hiểu và sự đồng cảm với người bệnh [12].

Song song với nhu cầu trên, các mô hình ngôn ngữ lớn (Large Language Model, LLM) đã đạt kết quả đáng chú ý trên nhiều bộ dữ liệu hỏi–đáp y khoa. Tuy nhiên, kết quả cao trên câu hỏi dạng thi hoặc trên một miền thử nghiệm hẹp chưa đồng nghĩa với khả năng sử dụng an toàn trong chăm sóc người bệnh. Khi câu hỏi dài, tình huống lâm sàng phức tạp hoặc thông tin bệnh nhân

chưa đầy đủ, mô hình vẫn có thể tạo ra câu trả lời trôi chảy nhưng sai, thiếu cảnh báo hoặc không phù hợp với quy trình thực tế. Vì vậy, LLM trong nghiên cứu này được xem là công cụ hỗ trợ truy xuất và tổng hợp thông tin, không phải một hệ thống tự chủ thay thế bác sĩ.

1.1.2 Sự tiến hóa của các hệ thống hỏi đáp y tế và điểm nghẽn công nghệ

Để giải quyết bài toán tra cứu và tư vấn thông tin y tế, các hệ thống hỏi đáp tự động đã trải qua quá trình phát triển qua nhiều thế hệ công nghệ với những đặc trưng và giới hạn riêng biệt.

Thế hệ đầu tiên và thứ hai của các hệ thống hỏi đáp y tế được xây dựng dựa trên các hệ trợ giúp ra quyết định lâm sàng bằng tập luật [1, 2] kết hợp với thuật toán truy xuất từ khóa truyền thống như BM25 hay TF-IDF. Mặc dù các mô hình này đảm bảo tính an toàn cao nhờ tuân thủ nghiêm ngặt quy tắc logic định trước, chúng bộc lộ hạn chế lớn về tính linh hoạt. Do phụ thuộc vào việc khớp từ khóa chính xác, hệ thống không thể hiểu được ngữ nghĩa sâu xa, ngữ cảnh phức tạp hoặc các cách diễn đạt đa dạng trong câu hỏi ngôn ngữ tự nhiên từ người bệnh.

Sự xuất hiện của kiến trúc Transformer [3] đã đánh dấu bước chuyển mình sang thế hệ thứ ba với sự bùng nổ của các mô hình ngôn ngữ lớn (LLM). Nhờ được huấn luyện trên tập ngữ liệu khổng lồ, mô hình ngôn ngữ lớn sở hữu khả năng hiểu và sinh ngôn ngữ tự nhiên mượt mà, giải quyết rào cản giao tiếp giữa con người và máy tính. Tuy nhiên, khi áp dụng trực tiếp vào lĩnh vực y tế đòi hỏi sự chính xác tuyệt đối, mô hình ngôn ngữ lớn độc lập lại vấp phải rào cản chí mạng là hiện tượng ảo giác. Do bản chất của LLM là sinh văn bản bằng cách dự đoán xác suất từ ngữ tiếp theo hoàn toàn dựa vào tri thức tích lũy từ quá trình huấn luyện, mô hình có xu hướng tự tạo ra các thông tin sai lệch, sai liều lượng thuốc hoặc đưa ra phác đồ điều trị không có thực nhưng với văn phong hết sức tự tin. Trong ngành y tế, rủi ro ảo giác có thể gây ảnh hưởng trực tiếp đến an toàn tính mạng của người bệnh.

Ngoài hiện tượng ảo giác, LLM độc lập còn gặp ba giới hạn thực tế: tri thức trong tham số có thể trở nên lỗi thời khi hướng dẫn lâm sàng thay đổi; người dùng khó xác định nguồn bằng chứng hỗ trợ câu trả lời; và mô hình có thể khiến người dùng quá tin vào kết quả tự động. Các câu hỏi liên quan đến thuốc, chống chỉ định, chẩn đoán hoặc xử trí nguy cơ cao vì thế không nên được giải quyết chỉ bằng tri thức ghi nhớ sẵn của mô hình.

Để vượt qua điểm nghẽn ảo giác của các mô hình ngôn ngữ lớn độc lập, kiến trúc truy xuất

tăng cường sinh nội dung (RAG) [5, 4] đã ra đời và tạo nên thế hệ thứ tư của các hệ thống hỏi đáp y tế.

Định nghĩa 1.1 (Truy xuất Tăng cường Sinh nội dung (RAG)). Truy xuất Tăng cường Sinh nội dung (RAG) là một kỹ thuật AI và mẫu thiết kế hệ thống kết hợp mô hình ngôn ngữ lớn với hệ thống truy xuất thông tin bên ngoài như cơ sở tri thức, chỉ mục tìm kiếm hay cơ sở dữ liệu [13, 14], nhằm đảm bảo các phản hồi sinh ra được căn cứ trực tiếp trên dữ liệu miền chuyên biệt và có thể cập nhật theo thời gian thực. Hệ thống RAG thực hiện truy xuất nội dung liên quan dựa trên truy vấn người dùng [13] để cung cấp ngữ cảnh đầu vào [6], cho phép mô hình sinh ra câu trả lời chính xác, có thể kiểm chứng mà không cần tái huấn luyện [13].

Định nghĩa trên được tổng hợp từ các góc nhìn bổ trợ lẫn nhau giữa tổ chức tiêu chuẩn (NIST [13]) và các nghiên cứu tổng quan học thuật tiêu biểu (Gao et al. [6], Cheng et al. [14]). Sự hội tụ giữa các định nghĩa này cho thấy RAG vừa là một mẫu thiết kế hệ thống giúp phản hồi luôn có căn cứ xác thực từ dữ liệu miền chuyên biệt, vừa là một kiến trúc linh hoạt cho phép cập nhật tri thức liên tục mà không cần tái huấn luyện mô hình [13, 6]. Đáng chú ý, RAG không bị giới hạn trong bất kỳ công nghệ truy xuất cụ thể nào mà có thể kết nối với đa dạng nguồn dữ liệu từ văn bản, cơ sở dữ liệu quan hệ đến đồ thị tri thức [14].

Chính nhờ cơ chế phân tách và xác thực tri thức chuẩn mực nêu trên, các nghiên cứu gần đây chứng minh rằng một mô hình mã nguồn mở quy mô vừa phải khi tích hợp RAG có thể đạt hiệu suất vượt trội hơn cả các mô hình độc quyền quy mô khổng lồ (như GPT-4) khi vận hành đơn lẻ không có cơ chế truy xuất [9, 6].

Tuy vậy, RAG không loại bỏ hoàn toàn hiện tượng ảo giác. Chất lượng câu trả lời vẫn phụ thuộc trực tiếp vào tài liệu được truy xuất: đoạn văn bản cũ, nhiễu, mâu thuẫn hoặc không đủ bằng chứng có thể khiến câu trả lời sai trở nên thuyết phục hơn vì có vẻ được hỗ trợ bởi nguồn tham khảo. Các kết quả trên MIRAGE cũng cho thấy hiệu quả thay đổi đáng kể theo kho tài liệu, bộ truy xuất và mô hình sinh được lựa chọn [8]. Trong hội thoại nhiều lượt, việc đưa toàn bộ lịch sử trao đổi vào câu lệnh còn có thể làm lệch ngữ cảnh. Do đó, lịch sử hội thoại phải được lọc, cô đọng và dùng để viết lại câu hỏi hiện tại thành một truy vấn độc lập trước khi truy xuất.

Một vấn đề khác là tính không đồng nhất của dữ liệu y khoa. Tài liệu có thể tồn tại dưới nhiều định dạng, chứa bảng hoặc sơ đồ khó trích xuất, sử dụng thuật ngữ khác nhau, có nhiều phiên bản, khác biệt giữa hướng dẫn quốc tế và quy trình địa phương, hoặc đã hết hiệu lực. Vì vậy,

việc chỉ phân đoạn tài liệu và lưu vào cơ sở dữ liệu vector là chưa đủ; mỗi đoạn cần kèm siêu dữ liệu về nguồn, chuyên khoa, ngày ban hành, phiên bản, phạm vi áp dụng và trạng thái hiệu lực để phục vụ lọc, xếp hạng và trích dẫn. Thực trạng này dẫn đến nhu cầu về một quy trình tích hợp truy xuất lai, mô hình hỏi–đáp y khoa, lớp bảo đảm chất lượng và cơ chế lựa chọn giữa trả lời, từ chối trả lời hoặc chuyển đến chuyên gia.

1.2 Động lực nghiên cứu

Việc phát triển một giải pháp hỏi đáp y khoa tin cậy xuất phát từ đòi hỏi cấp thiết trong cả nghiên cứu xử lý ngôn ngữ tự nhiên lẫn thực tiễn lâm sàng.

1.2.1 Ý nghĩa khoa học

Về mặt lý thuyết, mặc dù mô hình ngôn ngữ lớn thể hiện tiềm năng ấn tượng trong xử lý ngôn ngữ tự nhiên, việc triển khai công nghệ này vào dữ liệu y tế chuyên sâu vẫn vấp phải nhiều thách thức. Động lực khoa học cốt lõi của đề tài hướng tới việc thúc đẩy nghiên cứu các phương pháp RAG tiên tiến trên nền ngữ liệu chuyên ngành, nơi các cấu trúc thông tin phức tạp và thuật ngữ y khoa đặc thù đặt ra những giới hạn riêng biệt.

Bên cạnh đó, trước khi xây dựng các cải tiến nâng cao, việc khảo sát toàn diện và đánh giá thực nghiệm một quy trình RAG tiêu chuẩn đóng vai trò vô cùng quan trọng. Tiến trình này giúp làm sáng tỏ khả năng vận hành, đo lường mức độ kiểm soát hiện tượng ảo giác cũng như nhận diện những điểm nghẽn kỹ thuật vốn có của kiến trúc RAG cơ sở. Trên mốc so sánh đó, đề tài khảo sát giá trị bổ sung của truy xuất lai giữa ngữ nghĩa và từ khóa, tinh chỉnh LLM bằng các mẫu có bằng chứng, bảo đảm chất lượng đầu ra và chính sách phản hồi an toàn. Việc đánh giá tách biệt ba tầng truy xuất, sinh câu trả lời và hỏi–đáp đầu cuối còn giúp xác định lỗi phát sinh từ bộ truy xuất, mô hình sinh hay bộ lọc chất lượng, thay vì quy toàn bộ sai sót cho một chỉ số tổng quát [8, 9].

1.2.2 Ý nghĩa thực tiễn

Về mặt ứng dụng, đề tài được thúc đẩy bởi hai đòi hỏi thực tế từ đời sống và ngành y tế:

Thứ nhất, giải quyết áp lực quá tải thông tin cho đội ngũ bác sĩ, nhân viên y tế và sinh viên y khoa. Trong môi trường lâm sàng nhiều áp lực, một công cụ tự động tra cứu phác đồ điều trị cùng tài liệu chuyên khoa về bệnh lý về xương chính xác sẽ giúp rút ngắn thời gian tìm kiếm thủ

công và tối ưu hóa hiệu suất ra quyết định chuyên môn [12].

Thứ hai, định hướng hành vi y tế đúng đắn và bảo vệ sức khỏe cộng đồng. Trước thực trạng thông tin sai lệch lan truyền trên không gian mạng cùng nguy cơ biến chứng do tự ý điều trị, việc phát triển kênh tư vấn sức khỏe ban đầu an toàn, giải đáp thắc mắc các bệnh lý về xương kèm nguồn trích dẫn bằng chứng minh bạch sẽ góp phần nâng cao nhận thức và bảo vệ người bệnh [12].

Thứ ba, nâng cao tính minh bạch và khả năng kiểm soát rủi ro của hệ thống hỏi–đáp. Thay vì buộc mô hình luôn tạo câu trả lời, hệ thống có thể từ chối khi bằng chứng thiếu hoặc mâu thuẫn và chuyển đến bác sĩ khi nhận diện tình huống nguy cơ cao. Cơ chế này vừa giúp người dùng nhận biết giới hạn của công cụ, vừa duy trì vai trò giám sát của con người trong các quyết định lâm sàng.

Cuối cùng, quy trình xử lý dữ liệu có ý nghĩa thực tiễn đối với bảo vệ thông tin cá nhân: chỉ sử dụng phần bối cảnh bệnh nhân cần thiết và được phép, loại bỏ thông tin nhận dạng trong kho dữ liệu, đồng thời tránh đưa toàn bộ lịch sử hội thoại vào câu lệnh khi không cần thiết. Những nguyên tắc này giúp hệ thống phù hợp hơn với vai trò hỗ trợ tra cứu và giáo dục sức khỏe.

1.3 Phát biểu bài toán và hai pipeline của hệ thống

1.3.1 Đầu vào và đầu ra của bài toán

Nghiên cứu xem xét bài toán hỏi–đáp y khoa tin cậy dựa trên kiến trúc truy xuất tăng cường sinh nội dung (Retrieval-Augmented Generation, RAG) [5]. Hệ thống kết hợp tri thức y khoa đã được kiểm chứng với mô hình ngôn ngữ lớn (Large Language Model, LLM), qua đó ưu tiên bằng chứng truy xuất thay vì chỉ dựa vào tri thức được ghi nhớ trong tham số mô hình.

Trong giai đoạn huấn luyện, đầu vào thứ nhất là tập tài liệu y khoa đã được kiểm chứng

$$D = \{d_1, d_2, \dots, d_{N_D}\},$$

trong đó d_j là tài liệu thứ j và N_D là số tài liệu. Tập D có thể bao gồm giáo trình, hướng dẫn lâm sàng, phác đồ chẩn đoán–điều trị và các cặp hỏi–đáp đã được chuyên gia xác nhận. Đầu vào thứ hai là bộ dữ liệu hỏi–đáp

$$\mathcal{T}_{QA} = \{(q_i, u_i, h_i, y_i^*)\}_{i=1}^{N_Q},$$

trong đó N_Q là số mẫu huấn luyện; q_i là câu hỏi y khoa; u_i là phần bối cảnh bệnh nhân được phép

sử dụng; h_i là lịch sử hội thoại; và y_i^* là câu trả lời chuẩn của mẫu thứ i .

Sau tiền xử lý, tập tài liệu D được phân chia thành tập các đoạn văn bản

$$C = \{c_1, c_2, \dots, c_{N_C}\},$$

trong đó c_j là một đoạn văn bản (chunk) và N_C là tổng số đoạn. Các đoạn cùng siêu dữ liệu và biểu diễn tìm kiếm được lưu trong chỉ mục tri thức I . Với mỗi mẫu hỏi–đáp, hệ thống truy xuất tập bằng chứng $C_i^* \subseteq C$ để hình thành mẫu tinh chỉnh $(q_i, u_i, h_i, C_i^*, y_i^*)$.

Trong giai đoạn suy diễn, đầu vào của một lượt hỏi được biểu diễn bởi

$$X = (q, u, h, I),$$

trong đó q là câu hỏi hiện tại, u là bối cảnh bệnh nhân cần thiết và được phép sử dụng, h là lịch sử hội thoại, còn I là chỉ mục tri thức đã được xây dựng từ tập tài liệu D .

Đầu ra chính không chỉ là một câu trả lời mà là cặp

$$O = (\hat{y}, d), \quad d \in \Delta = \{\text{Answer}, \text{Abstain}, \text{Escalate}\},$$

trong đó $\hat{y}$ là phản hồi cuối cùng và d là quyết định thuộc tập hành động Δ . Quyết định *Answer* được chọn khi bằng chứng đủ mạnh và câu trả lời an toàn; *Abstain* biểu thị việc từ chối trả lời khi bằng chứng thiếu, mâu thuẫn hoặc độ tin cậy thấp; còn *Escalate* chuyển người dùng đến bác sĩ hoặc chuyên gia khi tình huống có nguy cơ cao, khẩn cấp hay vượt phạm vi của hệ thống. Khi phù hợp, đầu ra còn kèm các đoạn bằng chứng, nguồn trích dẫn, độ tin cậy và cảnh báo an toàn.

1.3.2 Các tham số cần học và biến trung gian

Các ẩn cần tìm của bài toán được chia thành hai nhóm. Nhóm thứ nhất là bộ tham số được học hoặc hiệu chỉnh trong giai đoạn huấn luyện:

$$\Theta = \{\phi, \theta, \psi\},$$

trong đó ϕ là tham số của bộ truy xuất, quyết định cách biểu diễn và chấm điểm độ liên quan giữa truy vấn với đoạn tài liệu; θ là tham số của LLM dùng để sinh câu trả lời; và ψ là tham số cùng các

ngưỡng của lớp bảo đảm chất lượng, dùng để đánh giá bằng chứng, độ an toàn và lựa chọn quyết định cuối cùng.

Nhóm thứ hai gồm các biến phải suy ra cho mỗi lượt hỏi:

- q' : truy vấn độc lập đã được chuẩn hóa từ câu hỏi hiện tại và ngữ cảnh liên quan;
- m và e : lần lượt là ý định y khoa và tập thực thể y khoa được nhận diện trong truy vấn;
- $\mathbf{z}_q \in \mathbb{R}^{d_e}$: vector nhúng d_e chiều của truy vấn;
- $C^* = \{c_{(1)}, \dots, c_{(k)}\} \subseteq C$: tập k đoạn bằng chứng liên quan nhất;
- $\tilde{y}$: câu trả lời nháp do LLM sinh ra;
- $\mathbf{v}$: vector điểm chất lượng gồm độ liên quan, độ bám sát bằng chứng, tính đầy đủ, độ chính xác trích dẫn, độ an toàn và độ tin cậy;
- $d \in \Delta$: quyết định cuối cùng của hệ thống.

1.3.3 Nguyên lý và phát biểu toán học tổng quát

Từ câu hỏi, bối cảnh bệnh nhân và lịch sử hội thoại, hàm tiền xử lý f_{pre} tạo truy vấn độc lập

$$q' = f_{\text{pre}}(q, u, h).$$

Quá trình này bao gồm kiểm tra đầu vào, cô đọng lịch sử, xác định ý định và trích xuất thực thể y khoa. Vector truy vấn được tạo bởi mô hình nhúng E_ϕ :

$$\mathbf{z}_q = E_\phi(q').$$

Để khai thác đồng thời tương đồng ngữ nghĩa và thuật ngữ chính xác, điểm truy xuất lai giữa truy vấn q' và đoạn c được xác định bởi

$$s_\phi(q', c) = \alpha s_{\text{dense}, \phi}(q', c) + (1 - \alpha) s_{\text{sparse}}(q', c),$$

trong đó $s_{\text{dense}, \phi}$ là điểm truy xuất đặc dựa trên biểu diễn ngữ nghĩa, s_{sparse} là điểm truy xuất thưa

dựa trên từ khóa, và $\alpha \in [0, 1]$ là hệ số phối hợp hai thành phần. Tập bằng chứng được chọn là

$$C^* = \text{TopK}_{c \in C} s_\phi(q', c),$$

sau đó có thể được lọc theo siêu dữ liệu và xếp hạng lại.

Gọi $\bar{h}$ là phần lịch sử hội thoại đã được cô đọng và I_{safe} là chỉ dẫn an toàn của hệ thống. Câu lệnh cuối cùng P được xây dựng bởi

$$P = \text{Concat}(I_{\text{safe}}, q', u, \bar{h}, C^*).$$

LLM với tham số θ sinh câu trả lời nháp theo

$$\tilde{y} = \arg \max_y P_\theta(y \mid q', u, \bar{h}, C^*).$$

Lớp bảo đảm chất lượng g_ψ đánh giá truy vấn, bằng chứng và câu trả lời nháp để tạo vector điểm $\mathbf{v}$ và quyết định

$$(\mathbf{v}, d) = g_\psi(q', u, C^*, \tilde{y}),$$

với chính sách tổng quát

$$d = \begin{cases} \text{Answer,} & \text{nếu bằng chứng đầy đủ, câu trả lời bám sát nguồn và an toàn,} \\ \text{Abstain,} & \text{nếu bằng chứng thiếu, mâu thuẫn hoặc độ tin cậy thấp,} \\ \text{Escalate,} & \text{nếu phát hiện tình huống nguy cơ cao hoặc cần thăm khám trực tiếp.} \end{cases}$$

Toàn bộ bài toán được biểu diễn bằng ánh xạ

$$F_{\phi, \theta, \psi} : (q, u, h, I) \longrightarrow (C^*, \hat{y}, d).$$


Mục tiêu là tối đa hóa hàm hữu dụng y khoa $\mathcal{U}$, phản ánh đồng thời độ chính xác, độ bám sát bằng chứng, độ an toàn và chất lượng quyết định, dưới các ràng buộc về thời gian phản hồi, bộ nhớ và độ dài cửa sổ ngữ cảnh:

$$(\phi^*, \theta^*, \psi^*) = \arg \max_{\phi, \theta, \psi} \mathbb{E}_{X \sim \mathcal{T}} [\mathcal{U}(F_{\phi, \theta, \psi}(X))].$$

Ở đây, $\mathcal{T}$ là phân phối dữ liệu đánh giá. Mục tiêu này nhấn mạnh rằng hệ thống không chỉ cần sinh câu trả lời đúng mà còn phải biết từ chối khi không đủ căn cứ và chuyển đến chuyên gia khi có rủi ro.

1.3.4 Pipeline huấn luyện

Pipeline huấn luyện tạo kho tri thức có thể truy xuất, dữ liệu tinh chỉnh RAG, LLM chuyên biệt và các ngưỡng chất lượng–an toàn. Tổng quan pipeline được trình bày trong Hình 1.1; quy trình gồm năm bước sau.



Hình 1.1: Pipeline huấn luyện của hệ thống hỏi–đáp y khoa dựa trên RAG

1.3.4.1 Bước 1: Thu thập và tiền xử lý dữ liệu

Tập tài liệu D được thu thập từ các nguồn y khoa chính thống như giáo trình, hướng dẫn lâm sàng, phác đồ chẩn đoán–điều trị và các cặp hỏi–đáp đã được kiểm chứng. Tài liệu thô ở dạng PDF, Word, HTML hoặc cơ sở dữ liệu được trích xuất văn bản; loại bỏ đầu trang, chân trang, ký tự lỗi và nội dung trùng lặp; chuẩn hóa thuật ngữ, đơn vị và định dạng; đồng thời loại bỏ hoặc ẩn thông tin nhận dạng bệnh nhân.

Hàm phân đoạn f_{chunk} chuyển tập tài liệu thành các đoạn:

$$C = f_{\text{chunk}}(D; \ell, s),$$

trong đó ℓ là kích thước đoạn và s là bước trượt. Mỗi đoạn c_j được gán siêu dữ liệu μ_j gồm tên tài liệu, chuyên khoa, chủ đề, tổ chức phát hành, ngày ban hành, phiên bản, vị trí trong tài liệu, phạm

vi áp dụng, trạng thái hiệu lực và độ tin cậy của nguồn. Đầu ra của bước này là tập các đoạn sạch (c_j, μ_j) đủ thông tin để truy xuất và trích dẫn.

1.3.4.2 Bước 2: Lập chỉ mục tri thức và huấn luyện bộ truy xuất

Mô hình nhúng E_ϕ biến mỗi đoạn c_j thành vector $\mathbf{z}_j = E_\phi(c_j) \in \mathbb{R}^{d_e}$. Vector, nội dung đoạn, siêu dữ liệu và thông tin trích dẫn được lưu trong chỉ mục đặc I_{dense} ; đồng thời, biểu diễn từ khóa được lưu trong chỉ mục thưa I_{sparse} . Chỉ mục tri thức hoàn chỉnh là $I = (I_{\text{dense}}, I_{\text{sparse}})$.

Khi có nhãn đoạn dương và đoạn âm, bộ truy xuất được huấn luyện để đưa câu hỏi gần đoạn liên quan và xa các đoạn không liên quan. Với c_i^+ là đoạn đúng và $\mathcal{B}_i^-$ là tập đoạn âm hoặc âm khó của câu hỏi q_i , hàm mất mát truy xuất được xác định bởi [4]

$$\mathcal{L}_{\text{ret}}(\phi) = - \sum_i \log \frac{\exp(s_\phi(q_i, c_i^+))}{\exp(s_\phi(q_i, c_i^+)) + \sum_{c^- \in \mathcal{B}_i^-} \exp(s_\phi(q_i, c^-))}.$$

Nếu tham số ϕ được cập nhật, toàn bộ vector đoạn phải được tạo lại và chỉ mục I_{dense} phải được cập nhật trước các bước tiếp theo.

1.3.4.3 Bước 3: Tạo dữ liệu huấn luyện RAG

Từ bộ $\mathcal{T}_{\text{QA}}$, câu hỏi được chuẩn hóa hoặc mở rộng bằng các cách diễn đạt tương đương, câu hỏi sinh từ tài liệu, câu hỏi nối tiếp trong hội thoại và trường hợp cố ý thiếu bằng chứng. Với mỗi câu hỏi, hệ thống thực hiện truy xuất lai, lấy Top- k đoạn, lọc theo siêu dữ liệu và có thể xếp hạng lại để thu được C_i^* .

Tập mẫu tinh chỉnh được tạo thành

$$\mathcal{T}_{\text{RAG}} = \{(q_i, u_i, \bar{h}_i, C_i^*, y_i^*, d_i^*)\}_{i=1}^{N_Q},$$

trong đó $\bar{h}_i$ là lịch sử đã cô đọng và $d_i^* \in \Delta$ là nhãn hành động chuẩn. Mỗi mẫu dạy mô hình đọc bằng chứng, trả lời dựa trên nguồn, trích dẫn đúng, biểu đạt độ không chắc chắn, từ chối khi bằng chứng không đủ và chuyển chuyên gia đối với tình huống nguy cơ cao.

1.3.4.4 Bước 4: Tinh chỉnh LLM và lớp quyết định

LLM nền được tinh chỉnh có giám sát (Supervised Fine-Tuning, SFT) trên $\mathcal{T}_{\text{RAG}}$. Hàm mất mát sinh câu trả lời là

$$\mathcal{L}_{\text{gen}}(\theta) = - \sum_i \sum_{t=1}^{T_i} \log P_{\theta}(y_{i,t}^* \mid y_{i,<t}^*, q_i, u_i, \bar{h}_i, C_i^*),$$

trong đó T_i là độ dài câu trả lời chuẩn và $y_{i,<t}^*$ là các token đứng trước vị trí t . Lớp bảo đảm chất lượng được học hoặc hiệu chỉnh bằng hàm mất mát $\mathcal{L}_{\text{safe}}(\psi)$, bao gồm lỗi phân loại quyết định d_i^* và các lỗi liên quan đến độ bám sát bằng chứng, trích dẫn và an toàn.

Hàm mục tiêu tổng hợp được viết dưới dạng

$$\mathcal{L} = \lambda_{\text{ret}} \mathcal{L}_{\text{ret}} + \lambda_{\text{gen}} \mathcal{L}_{\text{gen}} + \lambda_{\text{safe}} \mathcal{L}_{\text{safe}},$$

trong đó các hệ số không âm λ_{ret} , λ_{gen} và λ_{safe} kiểm soát đóng góp tương đối của ba mục tiêu. Các thành phần có thể được tối ưu theo từng giai đoạn, nhưng phải được đánh giá lại trong cùng một pipeline đầu cuối.

1.3.4.5 Bước 5: Đánh giá và lựa chọn mô hình

Đánh giá được thực hiện ở ba tầng:


- **Tầng truy xuất:** sử dụng Recall@ k , Precision@ k , Mean Reciprocal Rank (MRR), normalized Discounted Cumulative Gain (nDCG) và tỷ lệ tài liệu chuẩn xuất hiện trong Top- k để kiểm tra khả năng tìm đúng bằng chứng [8].
- **Tầng sinh câu trả lời:** đánh giá độ chính xác y khoa, độ liên quan, độ trung thực và bám sát bằng chứng, tính đầy đủ, tỷ lệ ảo giác, độ chính xác của trích dẫn và độ an toàn [7, 11].
- **Tầng hỏi–đáp đầu cuối:** đánh giá toàn bộ chuỗi từ câu hỏi, truy xuất, xây dựng câu lệnh, sinh câu trả lời, kiểm tra chất lượng đến quyết định cuối cùng; trong đó kiểm tra riêng khả năng trả lời đúng, từ chối đúng và chuyển chuyên gia đúng.

Đầu ra của pipeline huấn luyện gồm chỉ mục tri thức I , tập mẫu $\mathcal{T}_{\text{RAG}}$, LLM hỏi–đáp y khoa đã tinh chỉnh, tham số hoặc ngưỡng chất lượng–an toàn ψ , kết quả đánh giá và checkpoint mô hình

tốt nhất.

1.3.5 Pipeline suy diễn

Pipeline suy diễn sử dụng các thành phần đã tạo trong huấn luyện để xử lý một lượt hỏi qua năm bước. Luồng xử lý từ đầu vào đến quyết định Answer–Abstain–Escalate được minh họa trong Hình 1.2.



Hình 1.2: Pipeline suy diễn và cơ chế quyết định phản hồi của hệ thống

1.3.5.1 Bước 1: Hiểu và tiền xử lý truy vấn

Hệ thống tiếp nhận câu hỏi q , bối cảnh bệnh nhân u và lịch sử hội thoại h . Bối cảnh bệnh nhân có thể gồm tuổi, giới tính, triệu chứng, tiền sử, thuốc đang dùng, dị ứng hoặc kết quả xét nghiệm, nhưng chỉ phần dữ liệu cần thiết và được phép mới được sử dụng. Đầu vào được kiểm tra về định dạng, phạm vi, dữ liệu nhạy cảm và dấu hiệu cấp cứu.

Lịch sử h được lọc và cô đọng thành $\bar{h}$ thay vì đưa nguyên văn toàn bộ hội thoại vào câu lệnh. Hàm f_{pre} viết lại câu hỏi nối tiếp thành truy vấn độc lập q' , nhận diện ngôn ngữ, chuẩn hóa thuật ngữ Việt–Anh, xác định ý định m và trích xuất các thực thể e như bệnh, thuốc, triệu chứng, liều lượng, thời gian và yếu tố nguy cơ.

1.3.5.2 Bước 2: Truy xuất bằng chứng

Truy vấn q' được mã hóa thành $\mathbf{z}_q$ bằng cùng mô hình E_ϕ đã dùng khi lập chỉ mục. Hệ thống kết hợp truy xuất đặc và truy xuất thưa theo điểm s_ϕ , lấy Top- k đoạn rồi lọc theo chuyên khoa, ngày ban hành, trạng thái hiệu lực và phạm vi áp dụng. Một bộ xếp hạng lại có thể đưa bằng chứng phù hợp nhất lên đầu và loại các đoạn nhiễu hoặc trùng lặp.

Đầu ra là tập C^* , trong đó mỗi đoạn đi kèm nội dung, nguồn tài liệu, ngày hoặc phiên bản, điểm liên quan và siêu dữ liệu cần thiết để trích dẫn. Nếu bằng chứng không đủ hoặc các nguồn mâu thuẫn nghiêm trọng, tín hiệu này được chuyển đến lớp quyết định thay vì bị che giấu ở bước sinh.

1.3.5.3 Bước 3: Xây dựng câu lệnh

Câu lệnh P gồm chỉ dẫn an toàn I_{safe} , truy vấn đã xử lý q' , phần bối cảnh bệnh nhân u có liên quan, lịch sử cô đọng $\bar{h}$, tập bằng chứng C^* và định dạng đầu ra yêu cầu. Chỉ dẫn an toàn buộc mô hình ưu tiên bằng chứng, không tự tạo chẩn đoán chắc chắn hoặc liều thuốc khi thiếu dữ liệu, nêu rõ giới hạn, và đề nghị gặp chuyên gia khi có dấu hiệu nguy hiểm. Mỗi đoạn bằng chứng được đánh dấu nguồn rõ ràng để hỗ trợ kiểm tra trích dẫn.

1.3.5.4 Bước 4: Sinh câu trả lời nháp

LLM hỏi-đáp y khoa với tham số θ^* đọc câu lệnh P và tạo câu trả lời nháp $\tilde{y}$. Câu trả lời có thể gồm nội dung chính, giải thích, bằng chứng hỗ trợ, trích dẫn, cảnh báo và mức độ không chắc chắn. Bản nháp chưa được gửi trực tiếp cho người dùng mà phải qua lớp bảo đảm chất lượng.

1.3.5.5 Bước 5: Kiểm tra chất lượng và ra quyết định

Lớp g_{ψ^*} đánh giá bản nháp theo các tiêu chí: trả lời đúng trọng tâm; được bằng chứng hỗ trợ; không thêm luận điểm ngoài nguồn; trích dẫn đúng; không bỏ sót cảnh báo quan trọng; không gây hại; nhất quán với bối cảnh bệnh nhân; và đủ tin cậy để phản hồi. Kết quả tạo quyết định cuối cùng:

- **Answer:** bằng chứng đủ mạnh, câu trả lời bám sát tài liệu, trích dẫn hợp lệ và không phát hiện rủi ro nghiêm trọng;
- **Abstain:** không tìm được bằng chứng phù hợp, nguồn mâu thuẫn, câu hỏi thiếu thông tin, độ tin cậy thấp hoặc nằm ngoài phạm vi hệ thống;
- **Escalate:** có dấu hiệu cấp cứu, cần khám trực tiếp, liên quan đến quyết định điều trị nguy cơ cao, phản ứng thuốc nghiêm trọng hoặc cần bác sĩ đánh giá hồ sơ đầy đủ.

Như vậy, hai pipeline liên kết với nhau qua chỉ mục tri thức I , mô hình truy xuất ϕ^* , LLM

θ^* và lớp quyết định ψ^* . Sự liên kết này bảo đảm các ký hiệu và thành phần được sử dụng thống nhất từ xây dựng dữ liệu, huấn luyện đến vận hành thực tế.

1.4 Các thách thức của bài toán

Quá trình xây dựng một hệ thống RAG chuyên biệt và tin cậy cho tập dữ liệu về các bệnh lý về xương phải đối mặt với sáu nhóm thách thức cốt lõi, bao phủ toàn bộ luồng vận hành của hệ thống:

1.4.1 Tính không đồng nhất, tính thời điểm và chất lượng của dữ liệu

Kho tri thức y khoa được tổng hợp từ giáo trình, hướng dẫn lâm sàng, phác đồ và các tài liệu ở nhiều định dạng nên thường không đồng nhất về cấu trúc. Bảng, sơ đồ hoặc văn bản trích xuất từ PDF có thể bị mất quan hệ ngữ nghĩa; cùng một bệnh hoặc thuốc có thể mang nhiều tên gọi; các hướng dẫn giữa tổ chức, quốc gia và thời điểm ban hành có thể khác nhau hoặc mâu thuẫn. Nếu hệ thống không quản lý nguồn, phiên bản, phạm vi áp dụng và trạng thái hiệu lực, một đoạn văn bản lỗi thời vẫn có thể được truy xuất với điểm liên quan cao. Vì vậy, chất lượng phân đoạn và siêu dữ liệu của từng đoạn là điều kiện tiên quyết, không chỉ là bước tiền xử lý kỹ thuật.

1.4.2 Giới hạn của bộ truy xuất trước rào cản thuật ngữ và nhiều ngữ nghĩa

Dữ liệu y khoa về các bệnh lý về xương sở hữu đặc thù với mật độ thuật ngữ chuyên ngành cao, bao gồm nhiều từ đồng nghĩa, từ mượn và danh từ viết tắt lâm sàng. Các thuật toán tìm kiếm theo từ khóa truyền thống như BM25 thường gặp hiện tượng bỏ sót tài liệu liên quan do sự bất đồng giữa từ ngữ người dùng truy vấn và thuật ngữ chính thống trong văn bản y học [9]. Ngược lại, các mô hình nhúng biểu diễn không gian đa chiều tuy cải thiện khả năng tra cứu ngữ nghĩa nhưng lại dễ vấp phải rào cản nhiễu sau truy xuất [8]. Các mô hình này có xu hướng trích xuất các đoạn văn bản có độ tương đồng biểu diễn cao (như cùng đề cập đến một nhóm thuốc) nhưng lại thiếu hụt những thông tin lâm sàng mang tính quyết định (như chống chỉ định hoặc liều lượng áp dụng cho bệnh nhân có bệnh nền), dẫn đến sự sai lệch ngữ cảnh đầu vào cho mô hình ngôn ngữ lớn [11].

1.4.3 Đứt gãy ngữ cảnh và năng lực suy luận y khoa đa bước

Một truy vấn y khoa trong thực tế lâm sàng thường đòi hỏi khả năng xử lý thông tin phức tạp và liên kết đa chiều. Để giải đáp một câu hỏi liên quan đến phác đồ điều trị kết hợp với tiền sử bệnh nền, hệ thống không thể chỉ dựa vào một đoạn văn bản đơn lẻ mà phải thực hiện tiến trình suy luận đa bước: xác định phác đồ điều trị chuẩn, sàng lọc danh sách chỉ định thuốc, và đối chiếu các tác dụng phụ đối với bệnh lý đi kèm [10]. Thách thức lớn nằm ở chỗ các kiến trúc RAG cơ bản thực hiện truy xuất đơn luồng thường làm đứt gãy mạch logic này. Việc chia nhỏ tài liệu thành các đoạn độc lập làm thất lạc thông tin liên kết, khiến mô hình ngôn ngữ lớn tiếp nhận ngữ cảnh thiếu hụt hoặc bị nhiễu loạn giữa tập tài liệu truy xuất có độ dài lớn [8].

Trong hội thoại nhiều lượt, lịch sử trao đổi và bối cảnh bệnh nhân còn tích lũy thêm thông tin không liên quan, lỗi thời hoặc mâu thuẫn với câu hỏi hiện tại. Đưa nguyên văn toàn bộ lịch sử vào câu lệnh vừa chiếm cửa sổ ngữ cảnh vừa có thể làm mô hình ưu tiên sai bằng chứng. Hệ thống vì thế phải cô đọng lịch sử, giữ lại các dữ kiện lâm sàng cần thiết và viết lại câu hỏi nối tiếp thành truy vấn độc lập mà không làm mất ý định ban đầu.

1.4.4 Xung đột tri thức và các dạng ảo giác y khoa

Khi ngữ cảnh được trích xuất mang về các phác đồ y học mới nhưng lại mâu thuẫn với tri thức được huấn luyện trước trong tham số của mô hình ngôn ngữ lớn, hiện tượng xung đột tri thức sẽ xuất hiện. Sự mâu thuẫn này là nguyên nhân cốt lõi phát sinh bốn dạng ảo giác nguy hiểm trong tư vấn y tế [11, 8]:

- (1) **Suy luận lỗi [11]:** Mô hình kết nối sai logic giữa triệu chứng lâm sàng và phương pháp điều trị, dẫn đến việc đưa ra kết luận thiếu căn cứ xác thực từ tài liệu gốc.
- (2) **Bỏ sót thông tin [11]:** Mô hình tóm tắt quá mức, làm bỏ sót các cảnh báo lâm sàng quan trọng hoặc các chống chỉ định y khoa nghiêm trọng.
- (3) **Từ chối quá mức [11]:** Mô hình từ chối trả lời mặc dù dữ liệu ngữ cảnh đã cung cấp đầy đủ thông tin bằng chứng.
- (4) **Gán sai nguồn trích dẫn [11]:** Mô hình đưa ra câu trả lời nhưng lại đính kèm trích dẫn tới đoạn văn bản không chứa thông tin chứng minh.

1.4.5 Sự khắt khe trong tiêu chuẩn an toàn và đánh giá lâm sàng

Biên độ chấp nhận sai sót trong các ứng dụng y tế gần như bằng không. Câu trả lời của hệ thống không chỉ cần tuân thủ độ trung thực so với văn bản ngữ cảnh, mà còn phải đáp ứng các tiêu chuẩn lâm sàng nghiêm ngặt bao gồm độ chính xác y khoa và độ an toàn lâm sàng nhằm đảm bảo không gây hại cho người bệnh [15, 11]. Bên cạnh đó, do người sử dụng hệ thống bao gồm cả bệnh nhân và cộng đồng, câu trả lời còn phải đáp ứng yêu cầu về khả năng đọc hiểu (tránh sử dụng thuật ngữ quá hàn lâm gây khó hiểu) và sự đồng cảm trong giao tiếp y khoa [12]. Đây là những tiêu chuẩn đa chiều mà các bộ chỉ số đo lường tự động thông thường rất khó đánh giá một cách toàn diện.

Các độ đo tương đồng bề mặt như BLEU hoặc ROUGE không đủ để phản ánh rủi ro y khoa: một câu trả lời diễn đạt khác đáp án chuẩn vẫn có thể đúng, trong khi câu trả lời gần giống về từ ngữ vẫn có thể chứa một chi tiết nguy hiểm. Do đó, cần đánh giá riêng chất lượng truy xuất, độ chính xác y khoa, độ bám sát bằng chứng, tính đầy đủ, độ chính xác trích dẫn, khả năng từ chối hoặc chuyển chuyên gia và độ ổn định qua nhiều lượt hội thoại.

1.4.6 Bảo vệ dữ liệu cá nhân và duy trì giám sát của con người

Bối cảnh bệnh nhân và lịch sử hội thoại có thể chứa thông tin nhận dạng, tiền sử bệnh, thuốc đang dùng hoặc kết quả xét nghiệm nhạy cảm. Việc thu thập quá mức, lưu trữ không cần thiết hoặc đưa nguyên trạng các dữ liệu này vào dịch vụ mô hình có thể làm tăng nguy cơ lộ lọt thông tin. Hệ thống cần thực hiện giảm thiểu dữ liệu, ẩn danh và kiểm soát quyền sử dụng ngay từ khâu xây dựng kho tri thức đến suy diễn. Đồng thời, nguy cơ người dùng quá tin vào câu trả lời tự động đòi hỏi hệ thống phải biểu đạt độ không chắc chắn, nêu nguồn và duy trì cơ chế con người tham gia đối với các tình huống nguy cơ cao.

1.5 Đóng góp của nghiên cứu

Trên cơ sở kế thừa khung RAG chuẩn, nghiên cứu hướng đến các đóng góp về phương pháp luận và giá trị ứng dụng sau:

- (1) **Chuẩn hóa khung hệ thống RAG đầu cuối cho bài toán hỏi–đáp y khoa:** Đề xuất, cài đặt và đánh giá một quy trình gồm hai pipeline huấn luyện và suy diễn, kết hợp kho tri

thức đã kiểm chứng, bộ truy xuất, mô hình ngôn ngữ lớn và lớp bảo đảm chất lượng. Quy trình được chuyên biệt hóa cho dữ liệu về các bệnh lý về xương, đồng thời thiết lập mốc so sánh (baseline) để đánh giá các kỹ thuật RAG nâng cao trong tương lai.

- (2) **Xây dựng bộ dữ liệu và bộ câu hỏi đánh giá chuyên ngành về các bệnh lý về xương:** Thu thập, tiền xử lý và chuẩn hóa bộ ngữ liệu y khoa chuyên sâu từ các nguồn tài liệu chính thống, đồng thời xây dựng tập câu hỏi thực nghiệm nhằm cung cấp tài nguyên dữ liệu phục vụ nghiên cứu hỏi đáp y tế.
- (3) **Thiết kế cơ chế truy xuất lai và song ngữ phù hợp với dữ liệu y khoa:** Kết hợp truy xuất đặc (dense retrieval) để tìm theo ngữ nghĩa với truy xuất thưa (sparse retrieval) để nhận diện chính xác tên bệnh, thuốc, xét nghiệm và thuật ngữ chuyên môn. Quy trình chuẩn hóa thuật ngữ Việt–Anh hỗ trợ trường hợp ngôn ngữ câu hỏi khác ngôn ngữ tài liệu, câu hỏi trộn hai ngôn ngữ hoặc sử dụng tên thông dụng thay cho thuật ngữ y khoa chuẩn; kết quả sau đó được lọc và xếp hạng lại dựa trên siêu dữ liệu và độ tin cậy của nguồn.
- (4) **Chuyên biệt hóa mô hình sinh bằng các mẫu huấn luyện có bằng chứng:** Xây dựng mẫu tinh chỉnh có giám sát từ câu hỏi, bối cảnh bệnh nhân, lịch sử hội thoại đã cô đọng, bằng chứng truy xuất và câu trả lời chuẩn. Mục tiêu là giúp mô hình ưu tiên tài liệu được cung cấp, trích dẫn nguồn, biểu đạt độ không chắc chắn và không bổ sung thông tin không có căn cứ.
- (5) **Đề xuất lớp bảo đảm chất lượng và cơ chế an toàn Answer–Abstain–Escalate:** Sau khi sinh câu trả lời nháp, hệ thống đánh giá độ liên quan, độ bám sát bằng chứng, tính đầy đủ, tính đúng đắn của trích dẫn, mức độ rủi ro và độ tin cậy. Từ đó hệ thống lựa chọn trả lời khi đủ căn cứ, từ chối khi bằng chứng thiếu hoặc mâu thuẫn, hoặc chuyển đến chuyên gia khi tình huống có nguy cơ cao, thay vì buộc LLM luôn phải trả lời.
- (6) **Thực nghiệm và đánh giá hệ thống theo nhiều tầng:** Đánh giá riêng chất lượng truy xuất, chất lượng sinh và hiệu quả hỏi–đáp đầu cuối, bao gồm khả năng trả lời đúng, từ chối đúng và phát hiện trường hợp cần chuyển chuyên gia. Cách đánh giá này nhằm đo lường khả năng giảm thiểu hiện tượng ảo giác, nâng cao độ trung thực và độ tin cậy, đồng thời xác định lỗi đến từ bộ truy xuất, mô hình sinh hay lớp kiểm tra chất lượng.

Tài liệu tham khảo

- [1] L. L. E., et al. (2018). **A rule-based clinical decision model to support interpretation of multiple data in health examinations.** *International Journal of Medical Informatics*, 112, 128–135. <https://doi.org/10.1016/j.ijmedinf.2018.01.018>.
- [2] K. M., et al. (2021). **A Hybrid AI and Rule-Based Decision Support System for Disease Diagnosis and Management Using Labs.** *IEEE Access*, 9, 45120–45132. <https://doi.org/10.1109/ACCESS.2021.3066311>.
- [3] Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). **Attention is all you need.** In *Advances in Neural Information Processing Systems* (Vol. 30, pp. 5998–6008). <https://arxiv.org/abs/1706.03762>.
- [4] Karpukhin, V., Oğuz, B., Min, S., Lewis, P., Wu, L., Edunov, S., Chen, D., & Yih, W. T. (2020). **Dense passage retrieval for open-domain question answering.** *arXiv preprint arXiv:2004.04906*. <https://arxiv.org/abs/2004.04906>.
- [5] Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W. T., Rocktäschel, T., Riedel, S., & Kiela, D. (2020). **Retrieval-augmented generation for knowledge-intensive NLP tasks.** In *Advances in Neural Information Processing Systems* (Vol. 33, pp. 9459–9474). <https://arxiv.org/abs/2005.11401>.
- [6] Gao, Y., Xiong, Y., Gao, X., Jia, K., Pan, J., Bi, Y., Dai, Y., Sun, J., & Wang, H. (2023). **Retrieval-augmented generation for large language models: A survey.** *arXiv preprint arXiv:2312.10997*. <https://arxiv.org/abs/2312.10997>.
- [7] Es, S., James, J., Espinosa-Anke, L., & Schockaert, S. (2023). **RAGAS: Automated Evaluation of Retrieval Augmented Generation.** *arXiv preprint arXiv:2309.15217*. <https://arxiv.org/abs/2309.15217>.

- [8] Xiong, G., Jin, Q., Lu, Z., & Zhang, A. (2024). **Benchmarking Retrieval-Augmented Generation for Medicine**. In *Findings of the Association for Computational Linguistics (ACL)*. *arXiv preprint arXiv:2411.09213*. <https://arxiv.org/abs/2411.09213>.
- [9] Xiong, G., et al. (2024). **MedRAG: Towards Reliable Medical Question Answering with Retrieval-Augmented Generation**. *arXiv preprint arXiv:2404.14746*. <https://arxiv.org/abs/2404.14746>.
- [10] Kim, J., et al. (2024). **Improving Retrieval-Augmented Generation in Medicine with Iterative Follow-up Questions**. *arXiv preprint arXiv:2405.03124*. <https://arxiv.org/abs/2405.03124>.
- [11] Zhang, H., et al. (2024). **MedTrust-RAG: Evidence Verification and Trust Alignment for Biomedical Question Answering**. *arXiv preprint arXiv:2406.08210*. <https://arxiv.org/abs/2406.08210>.
- [12] Mueller, M., et al. (2024). **Development and Evaluation of a Retrieval-augmented Generation Chatbot for Orthopedic and Trauma Surgery Patient Education: A Mixed-methods Study**. *JMIR AI*, 3, e54321. <https://doi.org/10.2196/54321>.
- [13] National Institute of Standards and Technology. (2025). **Adversarial Machine Learning: A Taxonomy and Terminology of Attacks and Mitigations**. *NIST AI 100-2e2025*. <https://doi.org/10.6028/NIST.AI.100-2e2025>.
- [14] Cheng, M., Luo, Y., Ouyang, J., Liu, Q., Liu, H., Li, L., Yu, S., Zhang, B., Cao, J., Ma, J., Wang, D., & Chen, E. (2025). **A Survey on Knowledge-Oriented Retrieval-Augmented Generation**. *arXiv preprint arXiv:2503.10677*. <https://arxiv.org/abs/2503.10677>.
- [15] World Health Organization. (2022). **Musculoskeletal Health**. *WHO Fact Sheets*. Truy cập ngày 29/07/2026. <https://www.who.int/news-room/fact-sheets/detail/musculoskeletal-health>.
- [16] Collaco, N., et al. (2026). **Integrating Fine-Tuning and Retrieval-Augmented Generation for Healthcare AI Systems: A Scoping Review**. *Journal of Healthcare Informatics Research*. <https://pubmed.ncbi.nlm.nih.gov/>.