

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH
KHOA CÔNG NGHỆ THÔNG TIN



BÁO CÁO KHÓA LUẬN TỐT NGHIỆP

Phát triển mô hình hỏi đáp tin cậy bệnh
lý về xương dựa trên mô hình ngôn ngữ
lớn và truy xuất tăng cường sinh nội
dung dựa trên văn bản

Giảng viên hướng dẫn:

Giảng viên hướng dẫn

Sinh viên thực hiện:

Sinh viên thực hiện

Thành phố Hồ Chí Minh, Ngày 30 tháng 7 năm 2026

Lời cảm ơn

Nhóm xin trân trọng cảm ơn **PGS. TS. Lý Quốc Ngọc** đã trực tiếp hướng dẫn, giảng dạy các nội dung lý thuyết chính và định hướng khoa học cho đề tài. Nhóm cũng xin cảm ơn **ThS. Nguyễn Mạnh Hùng** và **ThS. Phạm Thanh Tùng** đã hỗ trợ trong quá trình thực hành và cung cấp các kiến thức thực nghiệm quan trọng, góp phần giúp nhóm hoàn thành báo cáo này.

Mục lục

Lời cảm ơn	i
Chương 1: Tổng quan nghiên cứu	1
1.1 Bối cảnh nghiên cứu	1
1.1.1 Thực trạng tiếp cận thông tin y khoa về bệnh lý về xương	1
1.1.2 Sự tiến hóa của các hệ thống hỏi đáp y tế và điểm nghẽn công nghệ	2
1.2 Động lực nghiên cứu	3
1.2.1 Ý nghĩa khoa học	3
1.2.2 Ý nghĩa thực tiễn	4
1.3 Phát biểu bài toán và Khung kiến trúc RAG cơ bản	4
1.3.1 Nguyên lý cốt lõi và Bài toán RAG tổng quát	4
1.3.2 Các ẩn số cần tìm của bài toán	5
1.3.3 Giai đoạn xây dựng tri thức	5
1.3.4 Giai đoạn suy diễn và Tối ưu hóa toàn cục	6
1.3.5 Các tiêu chí đánh giá bài toán	7
1.4 Các thách thức của bài toán	9
1.4.1 Giới hạn của bộ truy xuất trước rào cản thuật ngữ và nhiều ngữ nghĩa	9
1.4.2 Đứt gãy ngữ cảnh và năng lực suy luận y khoa đa bước	9
1.4.3 Xung đột tri thức và các dạng ảo giác y khoa	10
1.4.4 Sự khắt khe trong tiêu chuẩn an toàn và đánh giá lâm sàng	10
1.5 Đóng góp của nghiên cứu	11
Tài liệu tham khảo	12

Danh sách hình vẽ

Danh sách bảng

Chương 1. Tổng quan nghiên cứu

1.1 Bối cảnh nghiên cứu

1.1.1 Thực trạng tiếp cận thông tin y khoa về bệnh lý về xương

Trong bối cảnh y học hiện đại, khối lượng tri thức lâm sàng, các báo cáo thực nghiệm và phác đồ điều trị các bệnh lý về xương (bao gồm các bệnh lý phổ biến như loãng xương, thoái hóa xương khớp, gãy xương và viêm xương) đang gia tăng với tốc độ nhanh chóng [15]. Sự tích lũy tri thức y học quy mô lớn vừa mở ra cơ hội nâng cao chất lượng chăm sóc sức khỏe, vừa tạo ra thách thức lớn trong việc tiếp cận và khai thác thông tin chính xác [9]. Thách thức này thể hiện rõ nét qua hai góc độ đối tượng sử dụng chính trong xã hội.

Đối với đội ngũ nhân viên y tế và sinh viên y khoa, việc tìm kiếm cũng như tổng hợp dữ liệu lâm sàng từ các bộ tài liệu y học chuyên ngành, sách giáo khoa hoặc cơ sở dữ liệu y sinh quy mô lớn đòi hỏi lượng thời gian đáng kể [12]. Trong môi trường thực hành áp lực cao, thời gian tra cứu kéo dài có thể làm chậm quá trình đưa ra quyết định chẩn đoán và chỉ định phác đồ điều trị [9]. Vì vậy, việc ứng dụng các công cụ tự động hóa nhằm hỗ trợ tra cứu tri thức chuẩn xác với tốc độ phản hồi tức thì là yêu cầu vô cùng cấp thiết.

Đối với người bệnh và cộng đồng, xu hướng tự tra cứu triệu chứng và phương pháp điều trị các bệnh lý về xương trên mạng Internet ngày càng trở nên phổ biến. Tuy nhiên, nguồn tin trên không gian mạng thường rơi vào tình trạng nhiễu loạn và thiếu sự kiểm chứng từ chuyên gia. Việc tiếp cận các dữ liệu sai lệch dễ dẫn đến hành vi tự chẩn đoán sai, tự ý sử dụng thuốc không theo chỉ định, gây ra những biến chứng nguy hiểm. Thực trạng này đặt ra đòi hỏi phải xây dựng các giải pháp công nghệ có khả năng tư vấn y học chính xác, minh bạch, đảm bảo độ an toàn lâm sàng, khả năng đọc hiểu và sự đồng cảm với người bệnh [12].

1.1.2 Sự tiến hóa của các hệ thống hỏi đáp y tế và điểm nghẽn công nghệ

Để giải quyết bài toán tra cứu và tư vấn thông tin y tế, các hệ thống hỏi đáp tự động đã trải qua quá trình phát triển qua nhiều thế hệ công nghệ với những đặc trưng và giới hạn riêng biệt.

Thế hệ đầu tiên và thứ hai của các hệ thống hỏi đáp y tế được xây dựng dựa trên các hệ trợ giúp ra quyết định lâm sàng bằng tập luật [1, 2] kết hợp với thuật toán truy xuất từ khóa truyền thống như BM25 hay TF-IDF. Mặc dù các mô hình này đảm bảo tính an toàn cao nhờ tuân thủ nghiêm ngặt quy tắc logic định trước, chúng bộc lộ hạn chế lớn về tính linh hoạt. Do phụ thuộc vào việc khớp từ khóa chính xác, hệ thống không thể hiểu được ngữ nghĩa sâu xa, ngữ cảnh phức tạp hoặc các cách diễn đạt đa dạng trong câu hỏi ngôn ngữ tự nhiên từ người bệnh.

Sự xuất hiện của kiến trúc Transformer [3] đã đánh dấu bước chuyển mình sang thế hệ thứ ba với sự bùng nổ của các mô hình ngôn ngữ lớn (LLM). Nhờ được huấn luyện trên tập ngữ liệu khổng lồ, mô hình ngôn ngữ lớn sở hữu khả năng hiểu và sinh ngôn ngữ tự nhiên mượt mà, giải quyết rào cản giao tiếp giữa con người và máy tính. Tuy nhiên, khi áp dụng trực tiếp vào lĩnh vực y tế đòi hỏi sự chính xác tuyệt đối, mô hình ngôn ngữ lớn độc lập lại vấp phải rào cản chí mạng là hiện tượng ảo giác. Do bản chất của LLM là sinh văn bản bằng cách dự đoán xác suất từ ngữ tiếp theo hoàn toàn dựa vào tri thức tích lũy từ quá trình huấn luyện, mô hình có xu hướng tự tạo ra các thông tin sai lệch, sai liều lượng thuốc hoặc đưa ra phác đồ điều trị không có thực nhưng với văn phong hết sức tự tin. Trong ngành y tế, rủi ro ảo giác có thể gây ảnh hưởng trực tiếp đến an toàn tính mạng của người bệnh.

Để vượt qua điểm nghẽn ảo giác của các mô hình ngôn ngữ lớn độc lập, kiến trúc truy xuất tăng cường sinh nội dung (RAG) [5, 4] đã ra đời và tạo nên thế hệ thứ tư của các hệ thống hỏi đáp y tế.

Định nghĩa 1.1 (Truy xuất Tăng cường Sinh nội dung (RAG)). Truy xuất Tăng cường Sinh nội dung (RAG) là một kỹ thuật AI và mẫu thiết kế hệ thống kết hợp mô hình ngôn ngữ lớn với hệ thống truy xuất thông tin bên ngoài như cơ sở tri thức, chỉ mục tìm kiếm hay cơ sở dữ liệu [13, 14], nhằm đảm bảo các phản hồi sinh ra được căn cứ trực tiếp trên dữ liệu miền chuyên biệt và có thể cập nhật theo thời gian thực. Hệ thống RAG thực hiện truy xuất nội dung liên quan dựa trên truy vấn người dùng [13] để cung cấp ngữ cảnh đầu vào [6], cho phép mô hình sinh ra câu trả lời chính

xác, có thể kiểm chứng mà không cần tái huấn luyện [13].

Định nghĩa trên được tổng hợp từ các góc nhìn bổ trợ lẫn nhau giữa tổ chức tiêu chuẩn (NIST [13]) và các nghiên cứu tổng quan học thuật tiêu biểu (Gao et al. [6], Cheng et al. [14]). Sự hội tụ giữa các định nghĩa này cho thấy RAG vừa là một mẫu thiết kế hệ thống giúp phản hồi luôn có căn cứ xác thực từ dữ liệu miền chuyên biệt, vừa là một kiến trúc linh hoạt cho phép cập nhật tri thức liên tục mà không cần tái huấn luyện mô hình [13, 6]. Đáng chú ý, RAG không bị giới hạn trong bất kỳ công nghệ truy xuất cụ thể nào mà có thể kết nối với đa dạng nguồn dữ liệu từ văn bản, cơ sở dữ liệu quan hệ đến đồ thị tri thức [14].

Chính nhờ cơ chế phân tách và xác thực tri thức chuẩn mực nêu trên, các nghiên cứu gần đây chứng minh rằng một mô hình mã nguồn mở quy mô vừa phải khi tích hợp RAG có thể đạt hiệu suất vượt trội hơn cả các mô hình độc quyền quy mô khổng lồ (như GPT-4) khi vận hành đơn lẻ không có cơ chế truy xuất [9, 6].

1.2 Động lực nghiên cứu

Việc phát triển một giải pháp hỏi đáp y khoa tin cậy xuất phát từ đòi hỏi cấp thiết trong cả nghiên cứu xử lý ngôn ngữ tự nhiên lẫn thực tiễn lâm sàng.

1.2.1 Ý nghĩa khoa học

Về mặt lý thuyết, mặc dù mô hình ngôn ngữ lớn thể hiện tiềm năng ấn tượng trong xử lý ngôn ngữ tự nhiên, việc triển khai công nghệ này vào dữ liệu y tế chuyên sâu vẫn vấp phải nhiều thách thức. Động lực khoa học cốt lõi của đề tài hướng tới việc thúc đẩy nghiên cứu các phương pháp RAG tiên tiến trên nền ngữ liệu chuyên ngành, nơi các cấu trúc thông tin phức tạp và thuật ngữ y khoa đặc thù đặt ra những giới hạn riêng biệt.

Bên cạnh đó, trước khi xây dựng các cải tiến nâng cao, việc khảo sát toàn diện và đánh giá thực nghiệm một quy trình RAG tiêu chuẩn đóng vai trò vô cùng quan trọng. Tiến trình này giúp làm sáng tỏ khả năng vận hành, đo lường mức độ kiểm soát hiện tượng ảo giác cũng như nhận diện những điểm nghẽn kỹ thuật vốn có của kiến trúc RAG cơ sở. Kết quả thu được sẽ thiết lập mốc so sánh khoa học nền tảng, tạo tiền đề cho các nghiên cứu mô hình chuyên sâu tiếp theo trong cộng đồng nghiên cứu xử lý ngôn ngữ tự nhiên y tế [8, 9].

1.2.2 Ý nghĩa thực tiễn

Về mặt ứng dụng, đề tài được thúc đẩy bởi hai đòi hỏi thực tế từ đời sống và ngành y tế:

Thứ nhất, giải quyết áp lực quá tải thông tin cho đội ngũ bác sĩ, nhân viên y tế và sinh viên y khoa. Trong môi trường lâm sàng nhiều áp lực, một công cụ tự động tra cứu phác đồ điều trị cùng tài liệu chuyên khoa về bệnh lý về xương chính xác sẽ giúp rút ngắn thời gian tìm kiếm thủ công và tối ưu hóa hiệu suất ra quyết định chuyên môn [12].

Thứ hai, định hướng hành vi y tế đúng đắn và bảo vệ sức khỏe cộng đồng. Trước thực trạng thông tin sai lệch lan truyền trên không gian mạng cùng nguy cơ biến chứng do tự ý điều trị, việc phát triển kênh tư vấn sức khỏe ban đầu an toàn, giải đáp thắc mắc các bệnh lý về xương kèm nguồn trích dẫn bằng chứng minh bạch sẽ góp phần nâng cao nhận thức và bảo vệ người bệnh [12].

1.3 Phát biểu bài toán và Khung kiến trúc RAG cơ bản

1.3.1 Nguyên lý cốt lõi và Bài toán RAG tổng quát

Để thiết lập nền tảng lý thuyết vững chắc cho nghiên cứu, bài toán hỏi đáp y tế tin cậy dựa trên kiến trúc Truy xuất Tăng cường Sinh nội dung (RAG) được mô hình hóa dựa trên nguyên lý đề xuất bởi Lewis et al. [5].

Nguyên lý cốt lõi: Kiến trúc RAG tách biệt hoàn toàn khả năng tư duy ngôn ngữ của mô hình với tri thức nghiệp vụ y khoa về các bệnh lý về xương. Bằng cách kết hợp cơ sở tri thức bên ngoài được thẩm định với năng lực sinh văn bản của mô hình ngôn ngữ lớn, hệ thống buộc phải sinh ra các câu trả lời dựa trên bằng chứng thực tế thay vì phụ thuộc vào bộ nhớ tham số có sẵn.

Cho cơ sở tri thức tài liệu y khoa đầu vào $D = \{d_1, d_2, \dots, d_N\} \in \mathcal{X}^N$ bao gồm N tài liệu đã qua kiểm chứng và truy vấn ngôn ngữ tự nhiên từ người dùng $q \in \mathcal{Q} \subseteq \mathcal{X}$. Mục tiêu của hệ thống là tìm hàm ánh xạ tổng quát $F^* : \mathcal{X}^N \times \mathcal{Q} \rightarrow \mathcal{A}$ sao cho cực đại hóa kỳ vọng chất lượng câu trả lời tối ưu $a^* \in \mathcal{A} \subseteq \mathcal{X}$:

$$F^* = \arg \max_F \mathbb{E}_{(D,q,a) \sim \mathcal{T}} [\mathcal{U}(F(D, q), a)]$$

trong đó $\mathcal{T}$ là tập dữ liệu đánh giá thực nghiệm và $\mathcal{U}$ là hàm đo lường hữu dụng của câu trả lời y học.

Trong mô hình sinh tự hồi quy [5], xác suất sinh chuỗi câu trả lời $a = (y_1, y_2, \dots, y_T)$ được

phân rã theo chuỗi lịch sử $y_{<t} = (y_1, \dots, y_{t-1})$:

$$P(a \mid D, q) = \prod_{t=1}^T P(y_t \mid y_{<t}, D, q)$$

1.3.2 Các ẩn số cần tìm của bài toán

Bài toán RAG được phân rã thành hai nhóm ẩn số chính tương ứng với hai giai đoạn vận hành:

(1) **Tập tham số cần học trong giai đoạn huấn luyện (Θ_{off}):**

- θ_e : Tập tham số của mô hình nhúng f_e , quyết định không gian biểu diễn ngữ nghĩa của các khối văn bản y khoa.
- θ_i : Tập tham số cấu trúc của chỉ mục tri thức, xác định cơ chế phân hoạch không gian để tối ưu tốc độ tra cứu.
- θ_g : Tập tham số của mô hình ngôn ngữ lớn, được tinh chỉnh để học cách ưu tiên sử dụng ngữ cảnh truy xuất hơn tri thức ghi nhớ nội tại.

(2) **Tập biến trung gian cần suy ra trong giai đoạn suy diễn (Θ_{on}):**

- $\mathbf{z}_q \in \mathbb{R}^d$: Vector biểu diễn ngữ nghĩa của truy vấn câu hỏi người dùng q .
- $C^* = \{c_{(1)}, c_{(2)}, \dots, c_{(k)}\} \subset C$: Tập hợp k khối văn bản ngữ cảnh y khoa liên quan nhất được trích xuất từ chỉ mục I .
- $p \in \mathcal{P}$: Chuỗi câu lệnh tăng cường ngữ cảnh được tổng hợp từ q và C^* .
- $a^* \in \mathcal{A}$: Chuỗi câu trả lời y khoa tối ưu cuối cùng được sinh ra.

1.3.3 Giai đoạn xây dựng tri thức

Giai đoạn xây dựng tri thức xác định tiến trình biến đổi $\Phi_{\text{off}} : \mathcal{X}^N \rightarrow \mathcal{I}$ nhằm chuẩn bị cơ sở tri thức có thể tra cứu và tinh chỉnh mô hình sinh. Tiến trình này gồm bốn bước xử lý:

(1) **Phân đoạn tài liệu:** Hàm $f_{\text{dp}} : \mathcal{X}^N \rightarrow \mathcal{C}^M$ phân chia N tài liệu thô D thành tập M khối văn bản ngữ cảnh $C = \{c_1, c_2, \dots, c_M\} \subset \mathcal{C}^M$ theo chiến lược phân đoạn với kích thước khối

ℓ và bước trượt s :

$$C = f_{\text{dp}}(D; \theta_{\text{dp}}), \quad c_i = d_j[k \cdot s : k \cdot s + \ell]$$

- (2) **Biểu diễn ngữ nghĩa:** Mô hình nhúng $f_e : \mathcal{C} \rightarrow \mathbb{R}^d$ mã hóa từng khối c_i thành vector $\mathbf{z}_i \in \mathbb{R}^d$.

Tham số θ_e được tối ưu hóa thông qua hàm mất mát tương phản in-batch softmax [4]:

$$\mathcal{L}_{\text{contrast}}(\theta_e) = -\mathbb{E} \left[\log \frac{\exp(\mathbf{z}_q^\top \mathbf{z}^+)}{\sum_{j=1}^B \exp(\mathbf{z}_q^\top \mathbf{z}_j)} \right]$$

- (3) **Xây dựng chỉ mục tri thức:** Hàm f_i cấu trúc hóa tập vector Z thành chỉ mục không gian vector I^* nhằm tối ưu hóa bài toán cân bằng giữa tốc độ tìm kiếm và độ chính xác hồi tiếp:

$$I^* = \arg \min_{I \in \mathcal{I}} \mathbb{E}_{\mathbf{z}_q} [\text{QueryTime}(I, \mathbf{z}_q)] \quad \text{s.t.} \quad \text{Recall@}k(I) \geq \rho$$

- (4) **Tinh chỉnh mô hình sinh:** Theo kiến trúc RAG gốc của Lewis et al. [5], các mẫu câu hỏi y khoa và câu trả lời chuẩn (q_i, y_i^*) được kết hợp với tập ngữ cảnh truy xuất C_i^* từ chỉ mục I để tạo tập dữ liệu tinh chỉnh $D_{\text{RAG}} = \{(q_i, C_i^*, y_i^*)\}$. Tham số θ_g của mô hình ngôn ngữ sinh được học thông qua bài toán tối ưu hóa xác suất điều kiện [5]:

$$\theta_g^* = \arg \min_{\theta_g} \sum_i \sum_{t=1}^T -\log P_{\theta_g}(y_{i,t}^* \mid y_{i,<t}^*, q_i, C_i^*)$$

1.3.4 Giai đoạn suy diễn và Tối ưu hóa toàn cục

Giai đoạn suy diễn xác định tiến trình sinh câu trả lời $\Phi_{\text{on}} : \mathcal{Q} \times \mathcal{I} \rightarrow \mathcal{A}$ thời gian thực khi nhận câu hỏi từ người dùng qua bốn bước xử lý:

- (1) **Mã hóa truy vấn:** Hàm mã hóa f_q chuyển đổi câu hỏi q thành vector ngữ nghĩa $\mathbf{z}_q = f_q(q; \theta_q) \in \mathbb{R}^d$ [5].
- (2) **Truy xuất ngữ cảnh tối ưu:** Trích xuất tập con k khối văn bản ngữ cảnh C^* từ chỉ mục I sao cho cực đại hóa điểm tích vô hướng giữa vector truy vấn $\mathbf{z}_q$ và vector biểu diễn của từng

khối $f_e(c_i)$ [5]:

$$C^* = \arg \max_{C' \subset C, |C'|=k} \sum_{c_i \in C'} \mathbf{z}_q^\top f_e(c_i)$$

thỏa mãn ràng buộc của số ngữ cảnh: $\text{Length}(C^*) \leq L_{\max}$.

- (3) **Xây dựng câu lệnh tăng cường:** Hàm f_p điền câu hỏi q và các đoạn ngữ cảnh C^* vào một mẫu câu lệnh định sẵn để tạo thành chuỗi chỉ dẫn $p = f_p(q, C^*; \theta_p) \in \mathcal{P}$ [5].
- (4) **Sinh câu trả lời có điều kiện:** Mô hình ngôn ngữ lớn sau khi fine-tune (θ_g^*) tính toán câu trả lời a^* cực đại hóa xác suất điều kiện tự hồi quy dựa trên câu lệnh p [5]:

$$a^* = \arg \max_{a \in \mathcal{A}} \sum_{t=1}^T \log P_{\theta_g^*}(y_t \mid y_{<t}, q, C^*)$$

Ràng buộc về Độ trung thực tri thức: Câu trả lời a^* bị ràng buộc bởi hàm đo lường độ trung thực [7] $\text{Faithfulness}(a^*, C^*) \in [0, 1]$, đòi hỏi tỷ lệ các luận điểm trong a^* được bảo chứng bởi C^* phải đạt ngưỡng tiệm cận tuyệt đối nhằm kiểm soát hiện tượng ảo giác:

$$\text{Faithfulness}(a^*, C^*) \geq 1 - \epsilon \quad (\text{với } \epsilon \rightarrow 0)$$

Tối ưu hóa Hệ thống Toàn cục: Kết hợp hai giai đoạn, toàn bộ mô hình RAG được phát biểu dưới dạng bài toán tối ưu hóa hệ thống toàn cục [5, 6]:

$$(\Theta_{\text{off}}^*, \Theta_{\text{on}}^*) = \arg \max_{\Theta_{\text{off}}, \Theta_{\text{on}}} \mathbb{E}_{(q,a)} [\mathcal{U}(\Phi_{\text{on}}(q, \Phi_{\text{off}}(D; \Theta_{\text{off}}); \Theta_{\text{on}}), a)]$$

dưới các ràng buộc thực thi về thời gian phản hồi ($\text{Latency} \leq \delta$), dung lượng bộ nhớ ($\text{Memory} \leq B$) và giới hạn độ dài token ($\text{Token Length} \leq L_{\max}$).

1.3.5 Các tiêu chí đánh giá bài toán

Chất lượng của giải pháp RAG được đánh giá đa chiều thông qua hàm hữu dụng tổng hợp $\mathcal{U}$, phân rã thành năm tầng tiêu chí đo lường chính được kế thừa từ các bộ chuẩn đánh giá uy tín trong cộng đồng nghiên cứu như RAGAS [7], MIRAGE [8], MedTrust-RAG [11] và tổng quan hệ

thống y tế của Collaco et al. [16]:

(1) **Tiêu chí đánh giá chất lượng giai đoạn truy xuất:**

- **Độ chính xác ngữ cảnh [7]:** Đo lường tỷ lệ các đoạn văn bản ngữ cảnh được trích xuất thực sự có chứa thông tin liên quan đến câu hỏi y khoa q , đảm bảo tập C^* không bị lẫn các đoạn nhiễu.
- **Độ phủ ngữ cảnh [7]:** Đo lường khả năng trích xuất đầy đủ tất cả các đoạn tài liệu y khoa cần thiết từ cơ sở tri thức để bảo chứng cho câu trả lời chuẩn y^* .
- **Chỉ số Recall@ k và MRR [8]:** Đo tỷ lệ xuất hiện và vị trí thứ hạng của đoạn tài liệu phác đồ y học chuẩn trong danh sách Top- k đoạn ngữ cảnh được trích xuất.

(2) **Tiêu chí đánh giá chất lượng giai đoạn sinh:**

- **Độ trung thực [7]:** Đo lường tỷ lệ các luận điểm trong câu trả lời a^* được suy ra trực tiếp và có căn cứ xác thực từ ngữ cảnh C^* , nhằm phát hiện và loại bỏ các luận điểm bịa đặt.
- **Độ tương quan câu trả lời [7]:** Đo lường mức độ đáp ứng đúng trọng tâm và trực tiếp của câu trả lời a^* đối với yêu cầu tra cứu của câu hỏi q .

(3) **Tiêu chí đánh giá tính xác thực của trích dẫn:**

- **Độ chính xác trích dẫn [11]:** Đánh giá xem nguồn tài liệu được đính kèm trong câu trả lời có thực sự chứa minh chứng hỗ trợ cho kết luận y khoa tương ứng hay không, tránh hiện tượng trích dẫn sai nguồn.

(4) **Tiêu chí đánh giá an toàn y khoa và ứng dụng lâm sàng:**

- **Tỷ lệ ảo giác [11]:** Đo lường tần suất phát sinh các thông tin y khoa sai lệch hoặc việc gán sai nguồn trích dẫn tài liệu trong câu trả lời.
- **Tính đầy đủ lâm sàng [8, 12]:** Đánh giá mức độ đảm bảo không bỏ sót các cảnh báo lâm sàng quan trọng, các chống chỉ định y khoa hoặc tác dụng phụ nghiêm trọng đối với các bệnh lý về xương.

(5) **Tiêu chí đánh giá hành vi hệ thống và phản hồi an toàn:**

- **Tỷ lệ từ chối hợp lý [11]:** Đánh giá khả năng của hệ thống trong việc chủ động từ chối trả lời khi dữ liệu ngữ cảnh không đủ căn cứ hoặc chứa thông tin mâu thuẫn, thay vì cố gắng đưa ra phỏng đoán nguy hiểm.
- **Tỷ lệ phát hiện tình huống cấp cứu [12]:** Đánh giá khả năng nhận biết các câu hỏi mang tính chấn thương xương gãy hoặc tình huống nguy cơ cao để đưa ra khuyến nghị chuyển người bệnh đến bác sĩ chuyên khoa kịp thời.

1.4 Các thách thức của bài toán

Quá trình xây dựng một hệ thống RAG chuyên biệt và tin cậy cho tập dữ liệu về các bệnh lý về xương phải đối mặt với bốn nhóm thách thức cốt lõi, bao phủ toàn bộ luồng vận hành của hệ thống:

1.4.1 Giới hạn của bộ truy xuất trước rào cản thuật ngữ và nhiều ngữ nghĩa

Dữ liệu y khoa về các bệnh lý về xương sở hữu đặc thù với mật độ thuật ngữ chuyên ngành cao, bao gồm nhiều từ đồng nghĩa, từ mượn và danh từ viết tắt lâm sàng. Các thuật toán tìm kiếm theo từ khóa truyền thống như BM25 thường gặp hiện tượng bỏ sót tài liệu liên quan do sự bất đồng giữa từ ngữ người dùng truy vấn và thuật ngữ chính thống trong văn bản y học [9]. Ngược lại, các mô hình nhúng biểu diễn không gian đa chiều tuy cải thiện khả năng tra cứu ngữ nghĩa nhưng lại dễ vấp phải rào cản nhiễu sau truy xuất [8]. Các mô hình này có xu hướng trích xuất các đoạn văn bản có độ tương đồng biểu diễn cao (như cùng đề cập đến một nhóm thuốc) nhưng lại thiếu hụt những thông tin lâm sàng mang tính quyết định (như chống chỉ định hoặc liều lượng áp dụng cho bệnh nhân có bệnh nền), dẫn đến sự sai lệch ngữ cảnh đầu vào cho mô hình ngôn ngữ lớn [11].

1.4.2 Đứt gãy ngữ cảnh và năng lực suy luận y khoa đa bước

Một truy vấn y khoa trong thực tế lâm sàng thường đòi hỏi khả năng xử lý thông tin phức tạp và liên kết đa chiều. Để giải đáp một câu hỏi liên quan đến phác đồ điều trị kết hợp với tiền sử bệnh nền, hệ thống không thể chỉ dựa vào một đoạn văn bản đơn lẻ mà phải thực hiện tiến trình suy luận đa bước: xác định phác đồ điều trị chuẩn, sàng lọc danh sách chỉ định thuốc, và đối chiếu các tác dụng phụ đối với bệnh lý đi kèm [10]. Thách thức lớn nằm ở chỗ các kiến trúc RAG cơ bản

thực hiện truy xuất đơn luồng thường làm đứt gãy mạch logic này. Việc chia nhỏ tài liệu thành các đoạn độc lập làm thất lạc thông tin liên kết, khiến mô hình ngôn ngữ lớn tiếp nhận ngữ cảnh thiếu hụt hoặc bị nhiễu loạn giữa tập tài liệu truy xuất có độ dài lớn [8].

1.4.3 Xung đột tri thức và các dạng ảo giác y khoa

Khi ngữ cảnh được trích xuất mang về các phác đồ y học mới nhưng lại mâu thuẫn với tri thức được huấn luyện trước trong tham số của mô hình ngôn ngữ lớn, hiện tượng xung đột tri thức sẽ xuất hiện. Sự mâu thuẫn này là nguyên nhân cốt lõi phát sinh bốn dạng ảo giác nguy hiểm trong tư vấn y tế [11, 8]:

- (1) **Suy luận lỗi [11]:** Mô hình kết nối sai logic giữa triệu chứng lâm sàng và phương pháp điều trị, dẫn đến việc đưa ra kết luận thiếu căn cứ xác thực từ tài liệu gốc.
- (2) **Bỏ sót thông tin [11]:** Mô hình tóm tắt quá mức, làm bỏ sót các cảnh báo lâm sàng quan trọng hoặc các chống chỉ định y khoa nghiêm trọng.
- (3) **Từ chối quá mức [11]:** Mô hình từ chối trả lời mặc dù dữ liệu ngữ cảnh đã cung cấp đầy đủ thông tin bằng chứng.
- (4) **Gán sai nguồn trích dẫn [11]:** Mô hình đưa ra câu trả lời nhưng lại đính kèm trích dẫn tới đoạn văn bản không chứa thông tin chứng minh.

1.4.4 Sự khắt khe trong tiêu chuẩn an toàn và đánh giá lâm sàng

Biên độ chấp nhận sai sót trong các ứng dụng y tế gần như bằng không. Câu trả lời của hệ thống không chỉ cần tuân thủ độ trung thực so với văn bản ngữ cảnh, mà còn phải đáp ứng các tiêu chuẩn lâm sàng nghiêm ngặt bao gồm độ chính xác y khoa và độ an toàn lâm sàng nhằm đảm bảo không gây hại cho người bệnh [15, 11]. Bên cạnh đó, do người sử dụng hệ thống bao gồm cả bệnh nhân và cộng đồng, câu trả lời còn phải đáp ứng yêu cầu về khả năng đọc hiểu (tránh sử dụng thuật ngữ quá hàn lâm gây khó hiểu) và sự đồng cảm trong giao tiếp y khoa [12]. Đây là những tiêu chuẩn đa chiều mà các bộ chỉ số đo lường tự động thông thường rất khó đánh giá một cách toàn diện.

1.5 Đóng góp của nghiên cứu

Nghiên cứu mang lại ba đóng góp cốt lõi cả về phương pháp luận khoa học và giá trị ứng dụng thực tiễn:

- (1) **Chuẩn hóa khung hệ thống RAG cho bài toán hỏi đáp y khoa:** Đề xuất, cài đặt và đánh giá toàn diện một quy trình RAG tiêu chuẩn kết hợp giữa mô hình nhúng văn bản và mô hình ngôn ngữ lớn, được tối ưu hóa cho dữ liệu chuyên sâu về các bệnh lý về xương. Quy trình này thiết lập mốc so sánh (baseline) được thực nghiệm bài bản, tạo nền tảng khoa học cho việc đánh giá các kỹ thuật RAG nâng cao trong tương lai.
- (2) **Xây dựng bộ dữ liệu và bộ câu hỏi đánh giá chuyên ngành về các bệnh lý về xương:** Thu thập, tiền xử lý và chuẩn hóa bộ ngữ liệu y khoa chuyên sâu từ các nguồn tài liệu chính thống, đồng thời xây dựng tập câu hỏi thực nghiệm nhằm cung cấp tài nguyên dữ liệu phục vụ nghiên cứu hỏi đáp y tế.
- (3) **Thực nghiệm và đánh giá hệ thống:** Thực hiện đánh giá thực nghiệm toàn diện trên kiến trúc RAG đề xuất nhằm đo lường khả năng giảm thiểu hiện tượng ảo giác, nâng cao độ trung thực và độ tin cậy của câu trả lời trong tư vấn thông tin y học.

Tài liệu tham khảo

- [1] L. L. E., et al. (2018). **A rule-based clinical decision model to support interpretation of multiple data in health examinations**. *International Journal of Medical Informatics*, 112, 128–135. <https://doi.org/10.1016/j.ijmedinf.2018.01.018>.
- [2] K. M., et al. (2021). **A Hybrid AI and Rule-Based Decision Support System for Disease Diagnosis and Management Using Labs**. *IEEE Access*, 9, 45120–45132. <https://doi.org/10.1109/ACCESS.2021.3066311>.
- [3] Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). **Attention is all you need**. In *Advances in Neural Information Processing Systems* (Vol. 30, pp. 5998–6008). <https://arxiv.org/abs/1706.03762>.
- [4] Karpukhin, V., Oğuz, B., Min, S., Lewis, P., Wu, L., Edunov, S., Chen, D., & Yih, W. T. (2020). **Dense passage retrieval for open-domain question answering**. *arXiv preprint arXiv:2004.04906*. <https://arxiv.org/abs/2004.04906>.
- [5] Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W. T., Rocktäschel, T., Riedel, S., & Kiela, D. (2020). **Retrieval-augmented generation for knowledge-intensive NLP tasks**. In *Advances in Neural Information Processing Systems* (Vol. 33, pp. 9459–9474). <https://arxiv.org/abs/2005.11401>.
- [6] Gao, Y., Xiong, Y., Gao, X., Jia, K., Pan, J., Bi, Y., Dai, Y., Sun, J., & Wang, H. (2023). **Retrieval-augmented generation for large language models: A survey**. *arXiv preprint arXiv:2312.10997*. <https://arxiv.org/abs/2312.10997>.
- [7] Es, S., James, J., Espinosa-Anke, L., & Schockaert, S. (2023). **RAGAS: Automated Evaluation of Retrieval Augmented Generation**. *arXiv preprint arXiv:2309.15217*. <https://arxiv.org/abs/2309.15217>.

- [8] Xiong, G., Jin, Q., Lu, Z., & Zhang, A. (2024). **Benchmarking Retrieval-Augmented Generation for Medicine**. In *Findings of the Association for Computational Linguistics (ACL)*. *arXiv preprint arXiv:2411.09213*. <https://arxiv.org/abs/2411.09213>.
- [9] Xiong, G., et al. (2024). **MedRAG: Towards Reliable Medical Question Answering with Retrieval-Augmented Generation**. *arXiv preprint arXiv:2404.14746*. <https://arxiv.org/abs/2404.14746>.
- [10] Kim, J., et al. (2024). **Improving Retrieval-Augmented Generation in Medicine with Iterative Follow-up Questions**. *arXiv preprint arXiv:2405.03124*. <https://arxiv.org/abs/2405.03124>.
- [11] Zhang, H., et al. (2024). **MedTrust-RAG: Evidence Verification and Trust Alignment for Biomedical Question Answering**. *arXiv preprint arXiv:2406.08210*. <https://arxiv.org/abs/2406.08210>.
- [12] Mueller, M., et al. (2024). **Development and Evaluation of a Retrieval-augmented Generation Chatbot for Orthopedic and Trauma Surgery Patient Education: A Mixed-methods Study**. *JMIR AI*, 3, e54321. <https://doi.org/10.2196/54321>.
- [13] National Institute of Standards and Technology. (2025). **Adversarial Machine Learning: A Taxonomy and Terminology of Attacks and Mitigations**. *NIST AI 100-2e2025*. <https://doi.org/10.6028/NIST.AI.100-2e2025>.
- [14] Cheng, M., Luo, Y., Ouyang, J., Liu, Q., Liu, H., Li, L., Yu, S., Zhang, B., Cao, J., Ma, J., Wang, D., & Chen, E. (2025). **A Survey on Knowledge-Oriented Retrieval-Augmented Generation**. *arXiv preprint arXiv:2503.10677*. <https://arxiv.org/abs/2503.10677>.
- [15] World Health Organization. (2022). **Musculoskeletal Health**. *WHO Fact Sheets*. Truy cập ngày 29/07/2026. <https://www.who.int/news-room/fact-sheets/detail/musculoskeletal-health>.
- [16] Collaco, N., et al. (2026). **Integrating Fine-Tuning and Retrieval-Augmented Generation for Healthcare AI Systems: A Scoping Review**. *Journal of Healthcare Informatics Research*. <https://pubmed.ncbi.nlm.nih.gov/>.